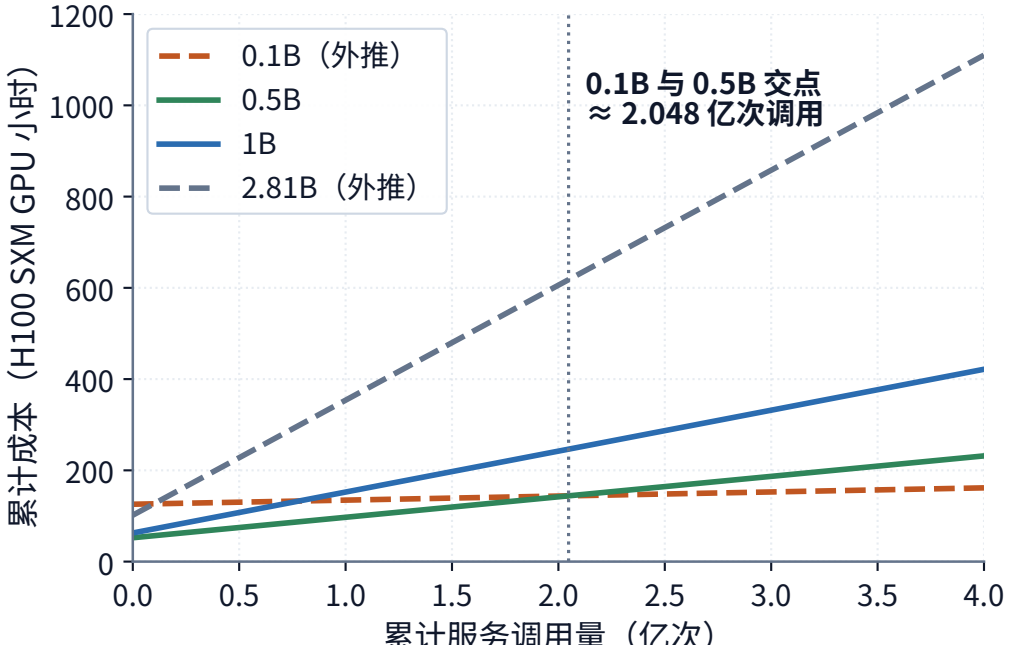
0.1B（外推）
0.5B
1B
2.81B（外推）
0.1B 与 0.5B 交点
≈ 2.048 亿次调用
累计成本（H100 SXM GPU 小时）
累计服务调用量（亿次）
0
200
400
600
800
1000
1200
0.0
0.5
1.0
1.5
2.0
2.5
3.0
3.5
4.0