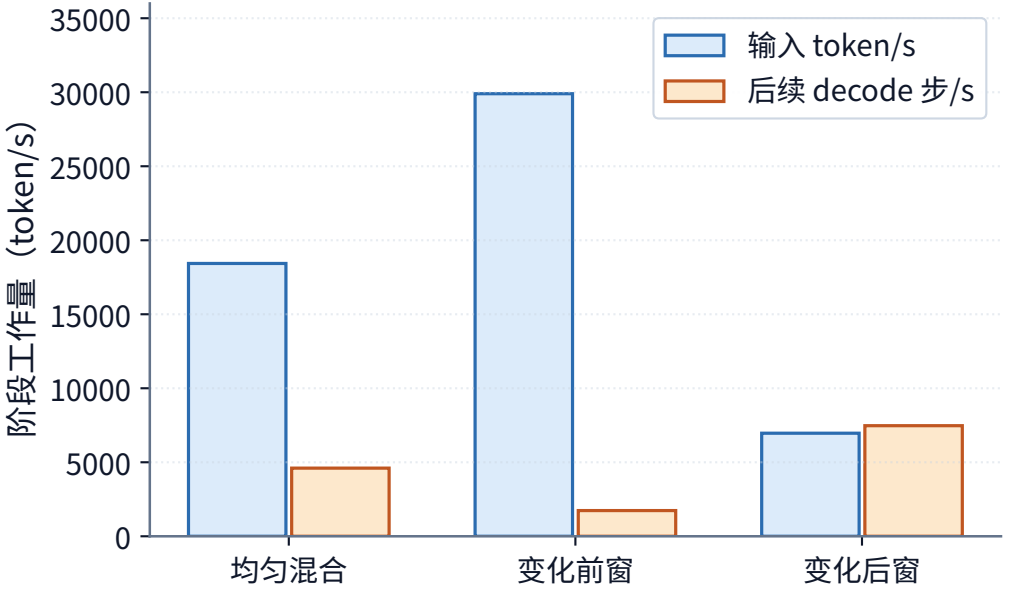
35000
30000
25000
20000
15000
10000
5000
0
阶段工作量（token/s）
输入 token/s
后续 decode 步/s
均匀混合
变化前窗
变化后窗