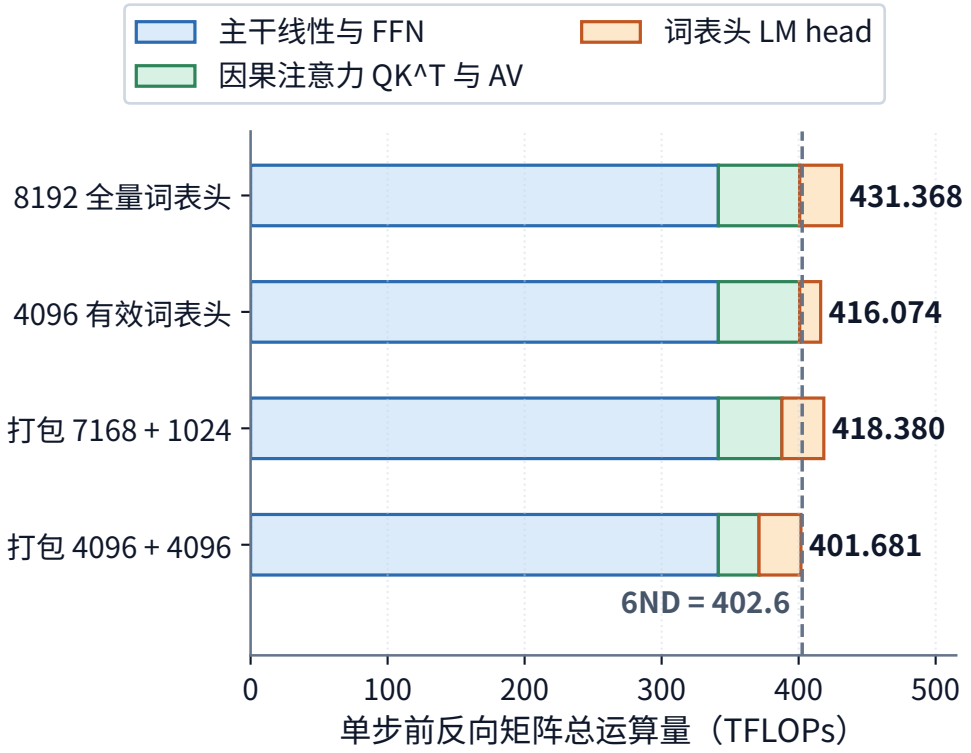
主干线性与 FFN
词表头 LM head
因果注意力 QK^T 与 AV
8192 全量词表头
4096 有效词表头
打包 7168 + 1024
打包 4096 + 4096
431.368
416.074
418.380
401.681
6ND = 402.6
0
100
200
300
400
500
单步前反向矩阵总运算量（TFLOPs）