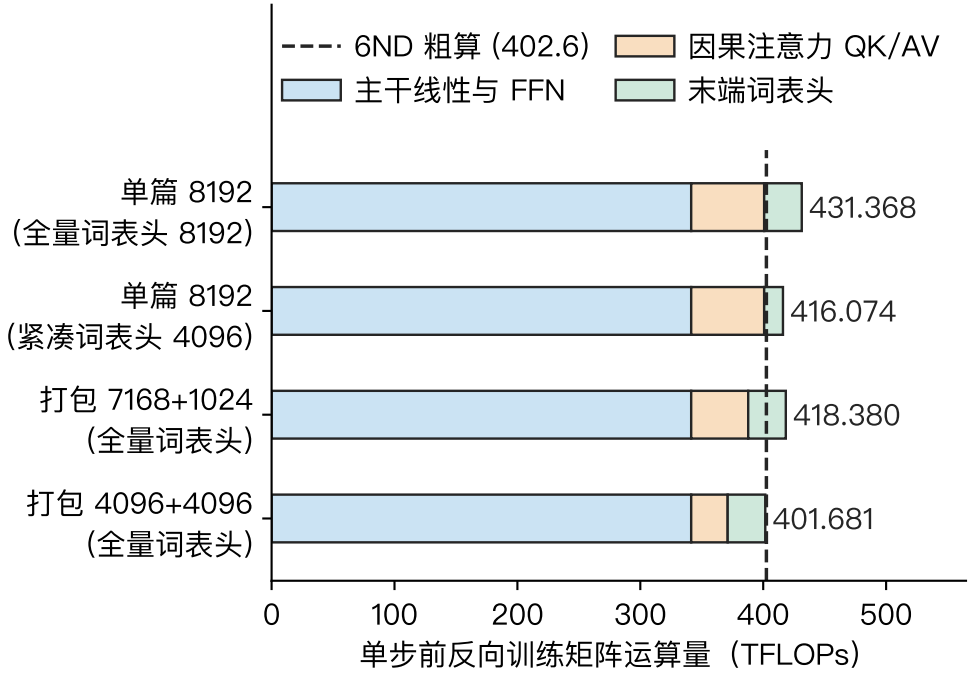
6ND 粗算 (402.6)
因果注意力 QK/AV
主干线性与 FFN
末端词表头
单篇 8192
(全量词表头 8192)
431.368
单篇 8192
(紧凑词表头 4096)
416.074
打包 7168+1024
(全量词表头)
418.380
打包 4096+4096
(全量词表头)
401.681
0
100
200
300
400
500
单步前反向训练矩阵运算量（TFLOPs）