从空状态处理 8,192 token 输入的前向激活体积对比

传统全层 Prefill

8,192 token × 40 层 = 327,680 token・层

CED 编码器阶段

8,192 token × 前 20 层 = 163,840 token・层

解码器局部重放

128 × 后 20 层 = 2,560

主干激活规模：327,680 → 166,400 token・层（缩减近一半）

需单独计入的固定与辅助项

全局 KV 投影、注意力核心运算及 MoE 路由开销

进入逐 token Decode 阶段后仍穿行完整 40 层主干