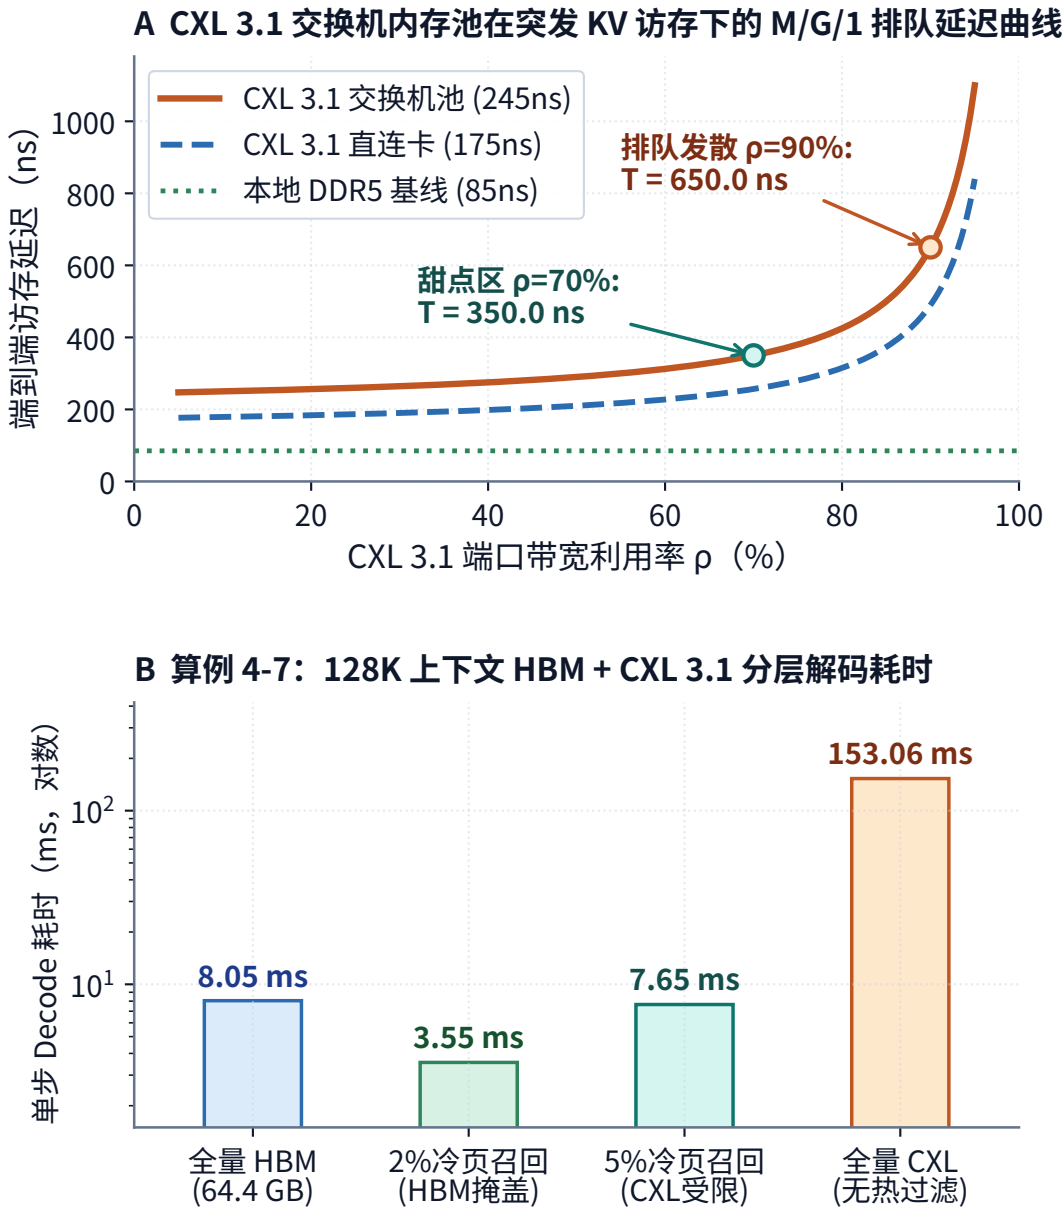
A CXL 3.1 交换机内存池在突发 KV 访存下的 M/G/1 排队延迟曲线
CXL 3.1 交换机池 (245ns)
CXL 3.1 直连卡 (175ns)
本地 DDR5 基线 (85ns)
排队发散 ρ=90%:
T = 650.0 ns
甜点区 ρ=70%:
T = 350.0 ns
端到端访存延迟（ns）
0
200
400
600
800
1000
0
20
40
60
80
100
CXL 3.1 端口带宽利用率 ρ（%）
B 算例 4-7：128K 上下文 HBM + CXL 3.1 分层解码耗时
单步 Decode 耗时（ms，对数）
$10^2$
$10^1$
8.05 ms
3.55 ms
7.65 ms
153.06 ms
全量 HBM
(64.4 GB)
2%冷页召回
(HBM掩盖)
5%冷页召回
(CXL受限)
全量 CXL
(无热过滤)