HBM3e (1024-bit) → HBM4 (2048-bit) 与 Vera Rubin 架构

HBM3e (B200: 192 GB)

单堆位宽: 1024-bit (16 通道)
Base Die: DRAM 无源直通
8 堆总带宽: 8.0 TB/s
FP8/4 峭点: 562.5 / 1,125

HBM4 (Rubin: 288 GB)

单堆位宽: 2048-bit (32 通道)
Base Die: TSMC 逻辑工艺
8 堆总带宽: 22.0 TB/s (2.75×)
FP8/4 峭点: 1,591 / 2,273

Vera CPU (88 核)
1.5TB LPDDR5X

→

NVLink-C2C
双向 1.8 TB/s

→

Rubin GPU
50 PFLOPS NVFP4

235B-A22B (NVFP4 激活 12.38 GB): B200 1.55 ms → Rubin 0.56 ms
VR200 NVL72: 72 GPU | 3.6 EFLOPS NVFP4 | 1.58 PB/s HBM4