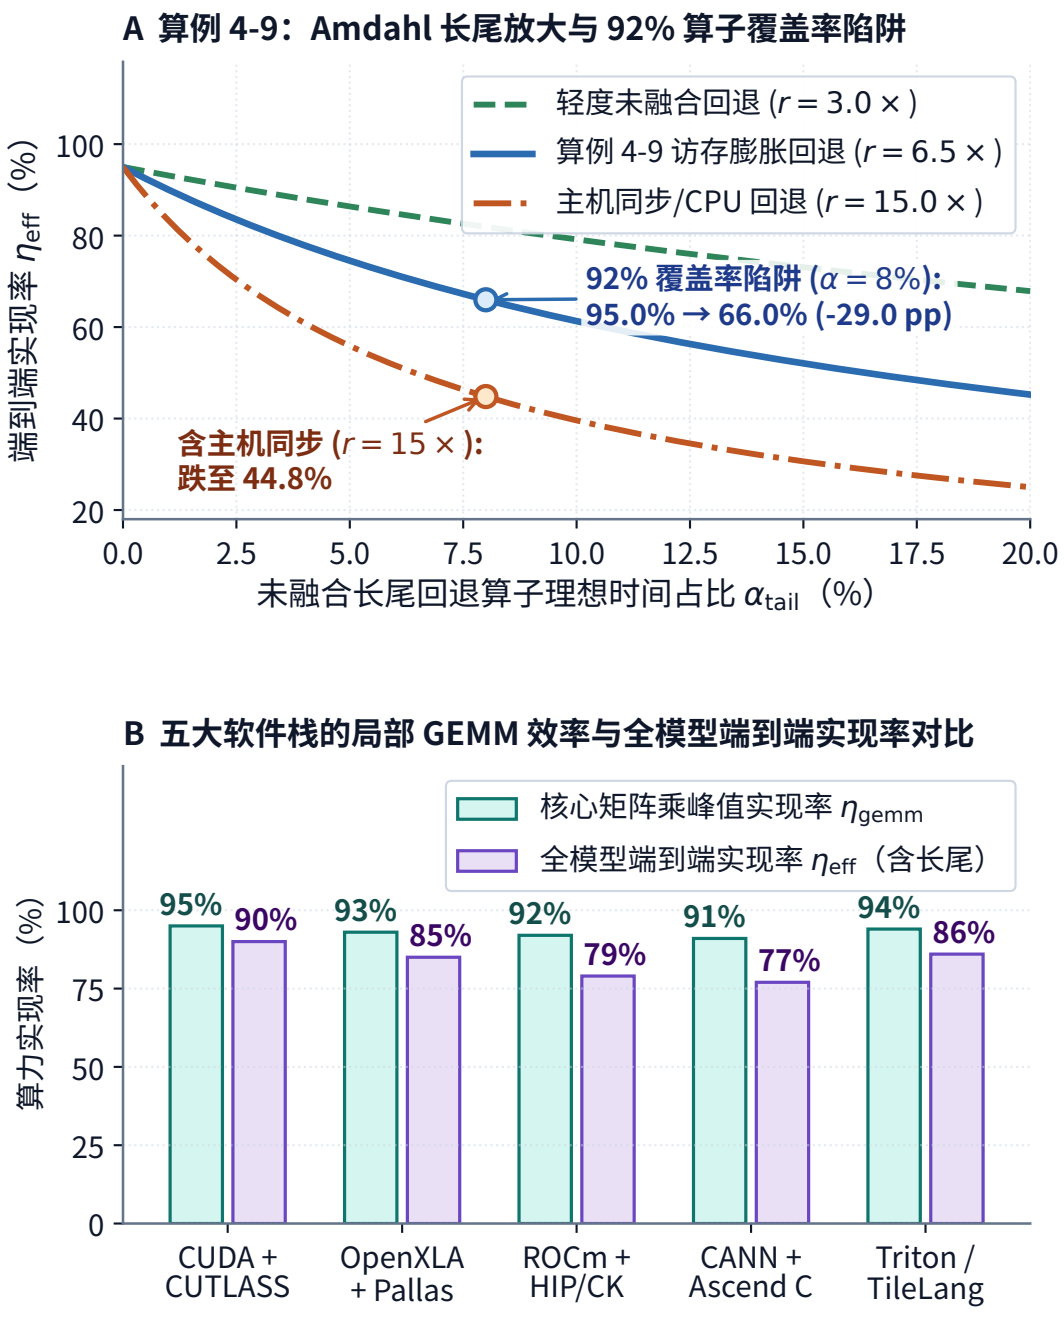
A 算例 4-9：Amdahl 长尾放大与 92% 算子覆盖率陷阱
轻度未融合回退 (r = 3.0 ×)
算例 4-9 访存膨胀回退 (r = 6.5 ×)
主机同步/CPU 回退 (r = 15.0 ×)
92% 覆盖率陷阱 (α = 8%):
95.0% → 66.0% (-29.0 pp)
含主机同步 (r = 15 ×):
跌至 44.8%
端到端实现率 η_eff（%）
未融合长尾回退算子理想时间占比 α_tail（%）
100
80
60
40
20
0.0
2.5
5.0
7.5
10.0
12.5
15.0
17.5
20.0
B 五大软件栈的局部 GEMM 效率与全模型端到端实现率对比
核心矩阵乘峰值实现率 η_gemm
全模型端到端实现率 η_eff（含长尾）
算力实现率（%）
100
75
50
25
0
95%
90%
93%
85%
92%
79%
91%
77%
94%
86%
CUDA + CUTLASS
OpenXLA + Pallas
ROCm + HIP/CK
CANN + Ascend C
Triton / TileLang