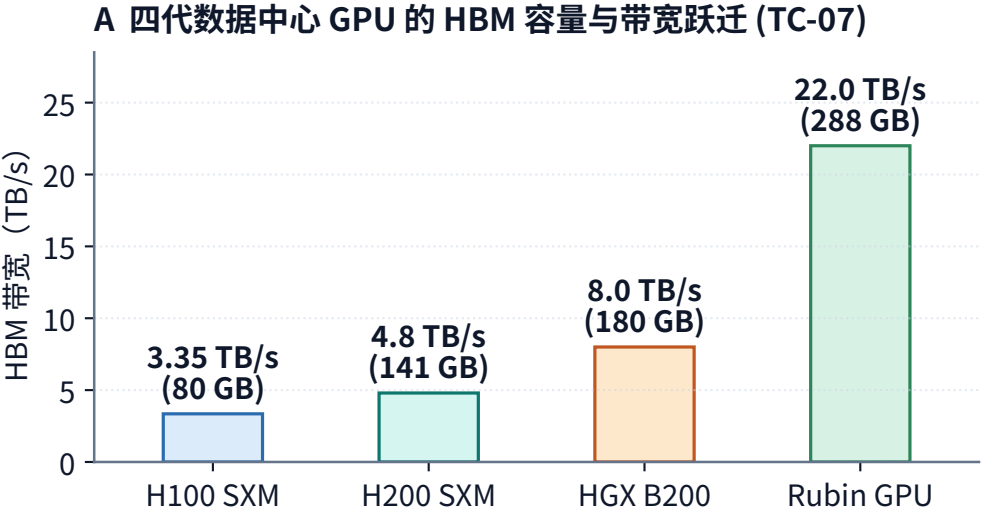
A 四代数据中心 GPU 的 HBM 容量与带宽跃迁 (TC-07)
HBM 带宽（TB/s）
0
5
10
15
20
25
3.35 TB/s
(80 GB)
4.8 TB/s
(141 GB)
8.0 TB/s
(180 GB)
22.0 TB/s
(288 GB)
H100 SXM
H200 SXM
HGX B200
Rubin GPU

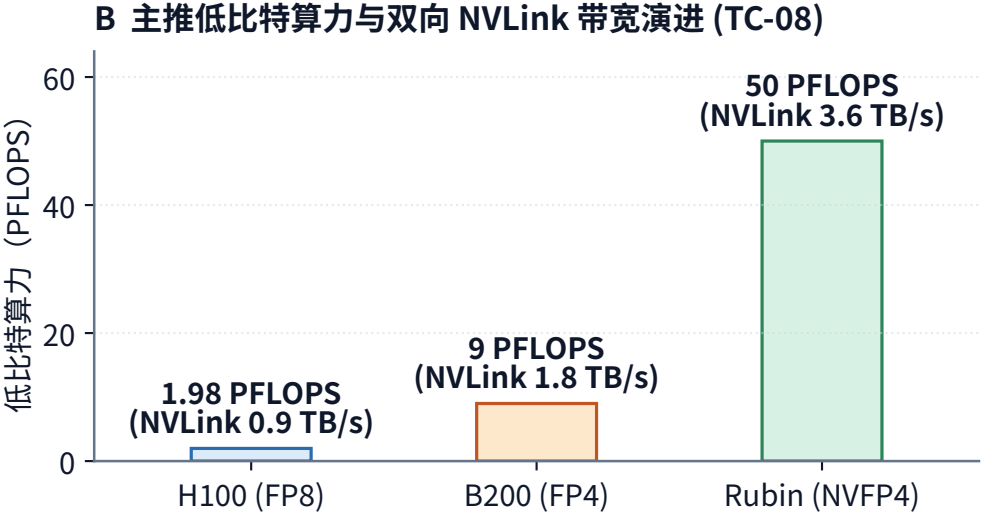
B 主推低比特算力与双向 NVLink 带宽演进 (TC-08)
低比特算力（PFLOPS）
0
20
40
60
1.98 PFLOPS
(NVLink 0.9 TB/s)
9 PFLOPS
(NVLink 1.8 TB/s)
50 PFLOPS
(NVLink 3.6 TB/s)
H100 (FP8)
B200 (FP4)
Rubin (NVFP4)