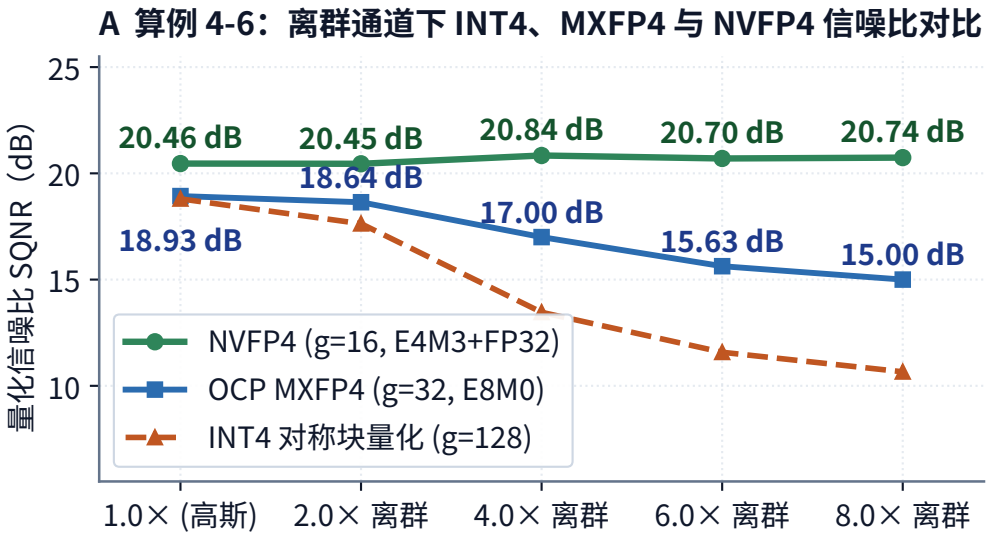
A 算例 4-6：离群通道下 INT4、MXFP4 与 NVFP4 信噪比对比
量化信噪比 SQNR（dB）
25
20
15
10
20.46 dB
20.45 dB
20.84 dB
20.70 dB
20.74 dB
18.64 dB
17.00 dB
15.63 dB
15.00 dB
18.93 dB
NVFP4 (g=16, E4M3+FP32)
OCP MXFP4 (g=32, E8M0)
INT4 对称块量化 (g=128)
1.0× (高斯)
2.0× 离群
4.0× 离群
6.0× 离群
8.0× 离群

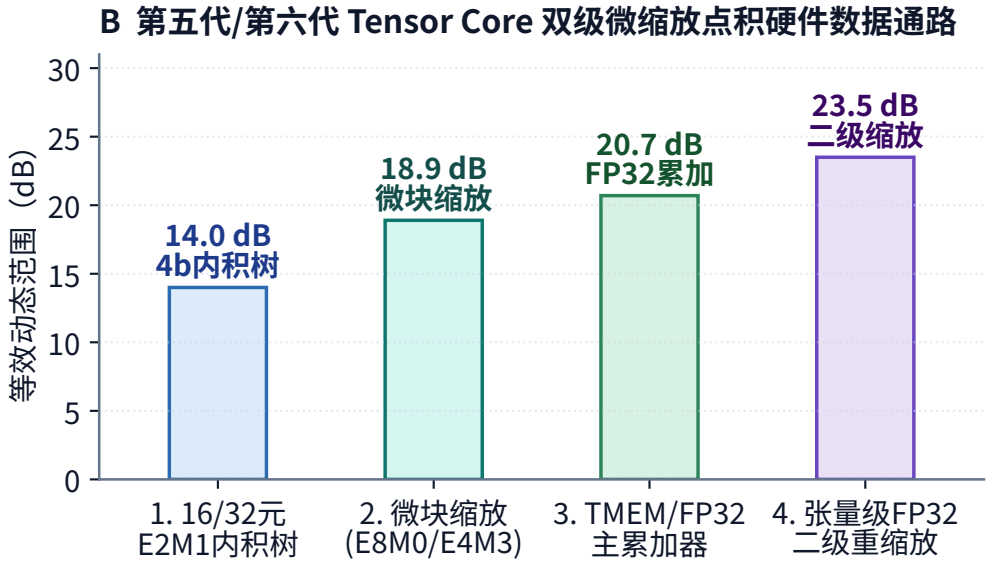
B 第五代/第六代 Tensor Core 双级微缩放点积硬件数据通路
等效动态范围（dB）
30
25
20
15
10
5
0
14.0 dB
4b内积树
18.9 dB
微块缩放
20.7 dB
FP32累加
23.5 dB
二级缩放
1. 16/32元
E2M1内积树
2. 微块缩放
(E8M0/E4M3)
3. TMEM/FP32
主累加器
4. 张量级FP32
二级重缩放