微缩放低精度格式：OCP MXFP4 vs. NVIDIA NVFP4

OCP MXFP4 (4.25 bits)

32 个 FP4 (E2M1) = 16 B
共享 1 个 E8M0 缩放 = 1 B
有效位宽: 4 + 8/32 = 4.25b
2 的幂次移位对齐，硬件极简

NVIDIA NVFP4 (4.50 bits)

16 个 FP4 (E2M1) = 8 B
共享 1 个 E4M3 缩放 = 1 B
外加张量级 FP32 二级缩放
有效位宽: 4.50b，信噪比更高

HBM 紧凑块读取
(17B/32 或 9B/16)

→

Tensor Core 前端
硬件解包与块缩放

→

FP32 累加器合并
+ 二级缩放输出

70B 权重: BF16 140 GB → NVFP4 39.38 GB → MXFP4 37.19 GB
671B 权重: BF16 1,342 GB → NVFP4 377.44 GB → MXFP4 356.47 GB