A HBM GPU 与纯 SRAM 推理 ASIC 的容量—带宽帕累托边界

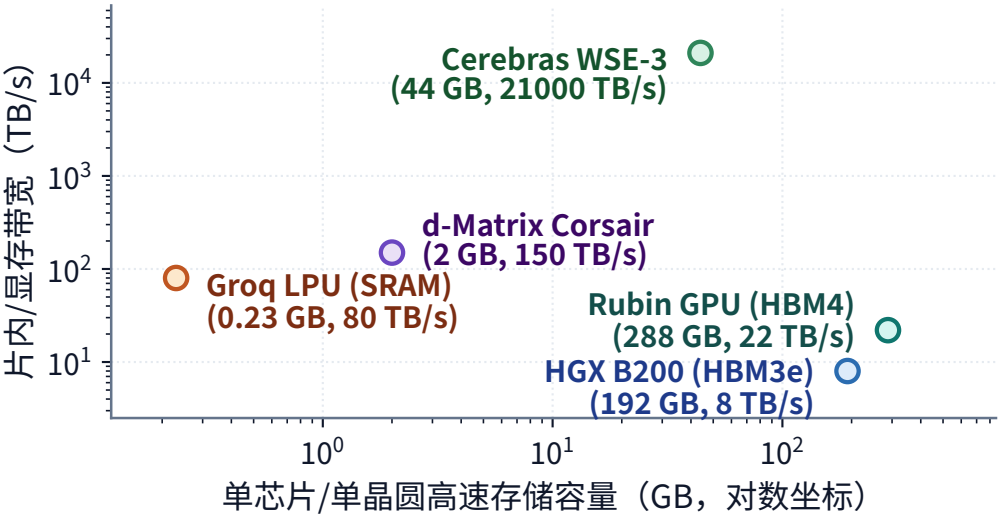

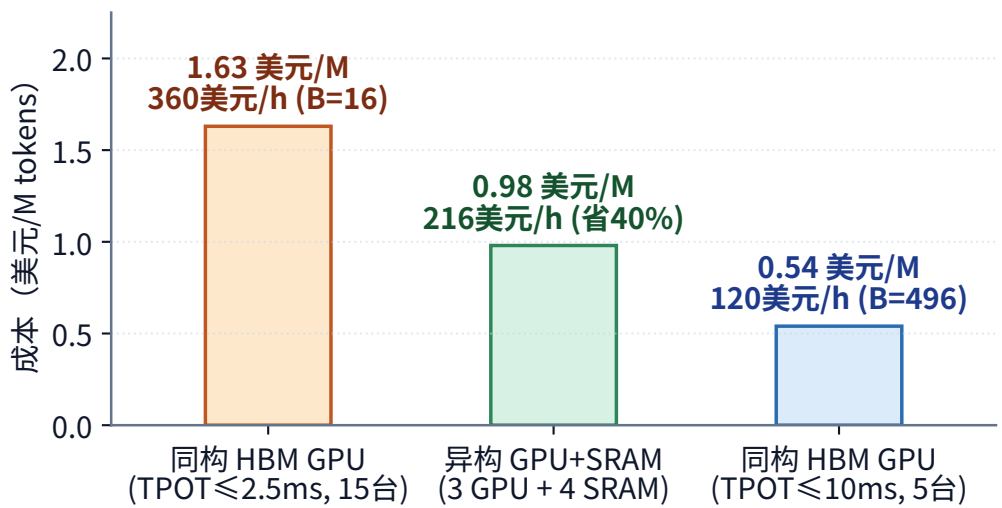
B 算例 4-5：120 req/s 下同构与异构 PD 分离成本对比