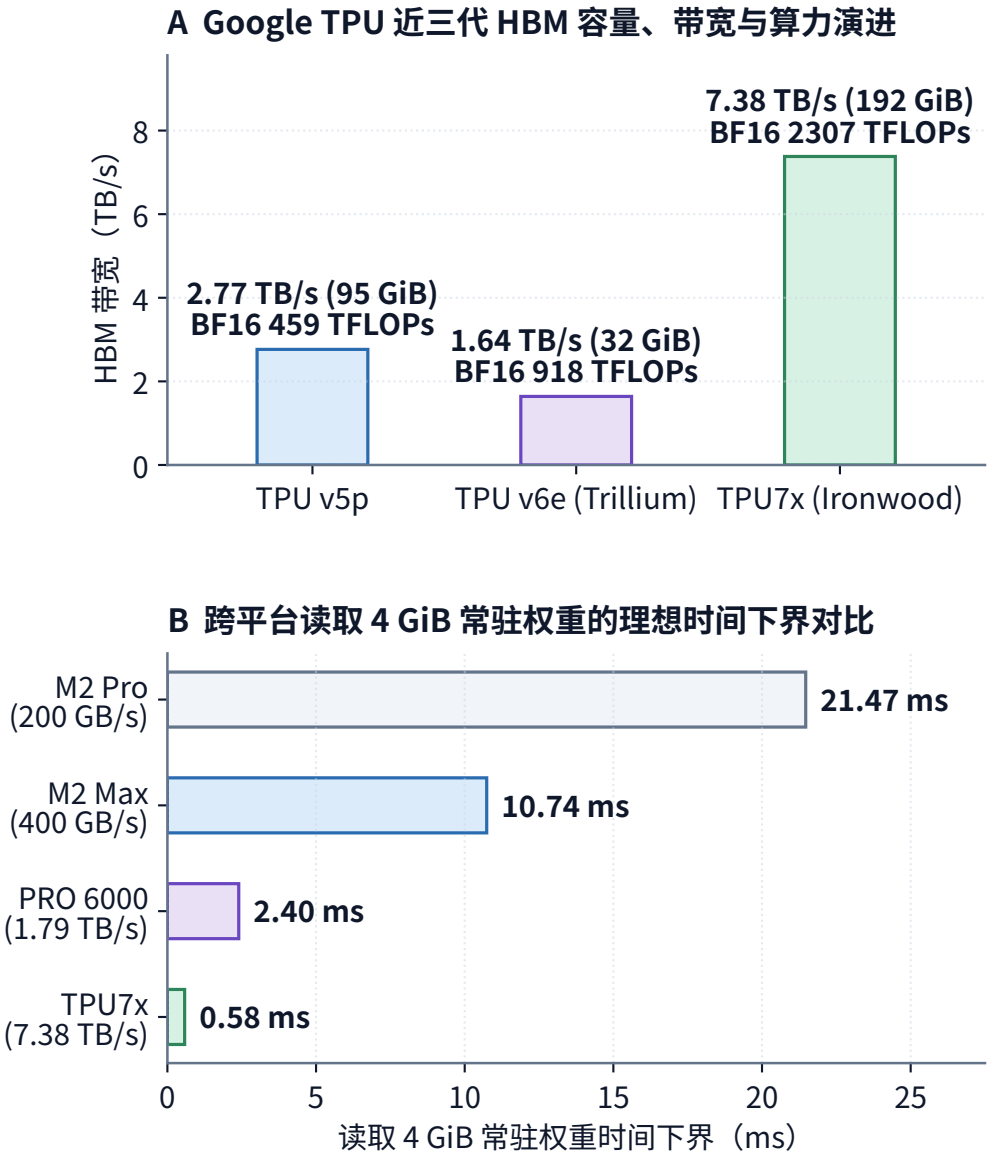
A Google TPU 近三代 HBM 容量、带宽与算力演进
HBM 带宽（TB/s）
0
2
4
6
8
2.77 TB/s (95 GiB)
BF16 459 TFLOPs
1.64 TB/s (32 GiB)
BF16 918 TFLOPs
7.38 TB/s (192 GiB)
BF16 2307 TFLOPs
TPU v5p
TPU v6e (Trillium)
TPU7x (Ironwood)
B 跨平台读取 4 GiB 常驻权重的理想时间下界对比
M2 Pro
(200 GB/s)
21.47 ms
M2 Max
(400 GB/s)
10.74 ms
PRO 6000
(1.79 TB/s)
2.40 ms
TPU7x
(7.38 TB/s)
0.58 ms
0
5
10
15
20
25
读取 4 GiB 常驻权重时间下界（ms）