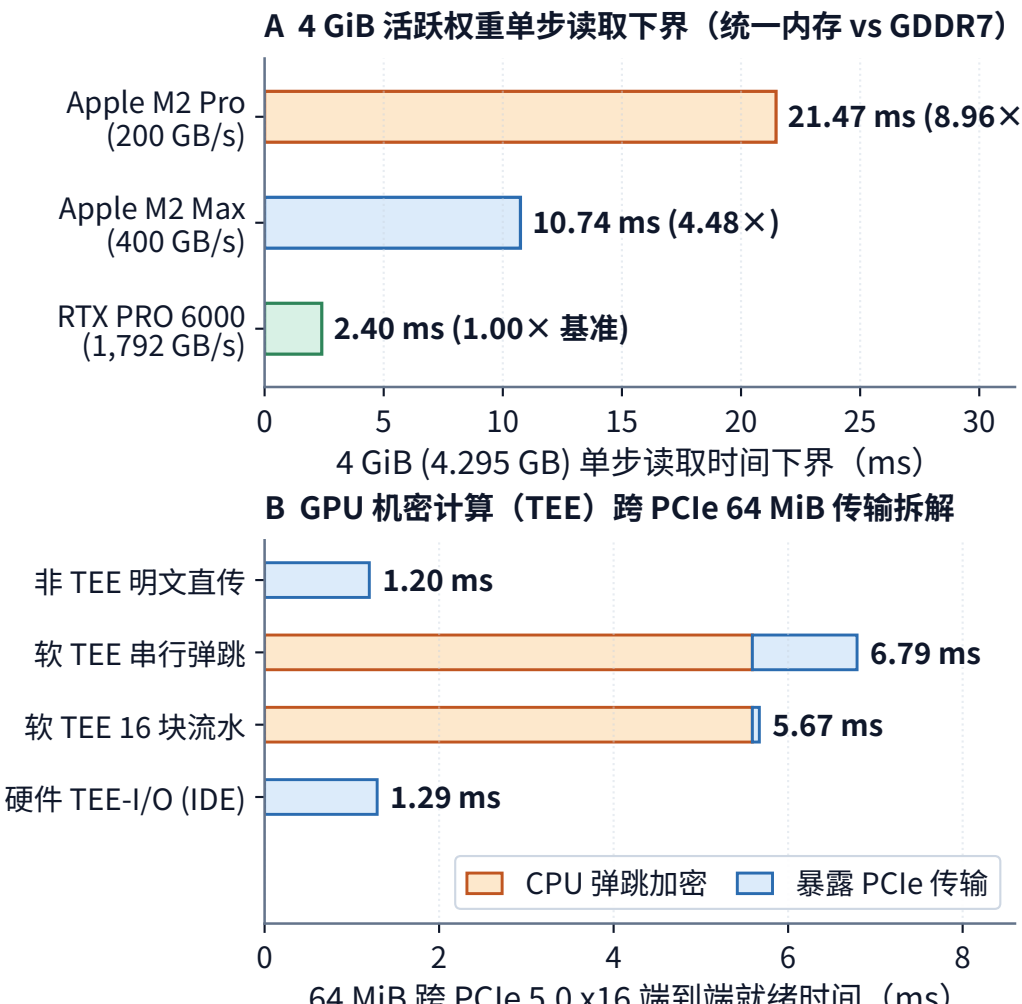
A 4 GiB 活跃权重单步读取下界（统一内存 vs GDDR7）
Apple M2 Pro (200 GB/s)
21.47 ms (8.96×)
Apple M2 Max (400 GB/s)
10.74 ms (4.48×)
RTX PRO 6000 (1,792 GB/s)
2.40 ms (1.00× 基准)
0
5
10
15
20
25
30
4 GiB (4.295 GB) 单步读取时间下界（ms）
B GPU 机密计算（TEE）跨 PCIe 64 MiB 传输拆解
非 TEE 明文直传
1.20 ms
软 TEE 串行弹跳
6.79 ms
软 TEE 16 块流水
5.67 ms
硬件 TEE-I/O (IDE)
1.29 ms
CPU 弹跳加密
暴露 PCIe 传输
0
2
4
6
8
64 MiB 跨 PCIe 5.0 x16 端到端就绪时间（ms）