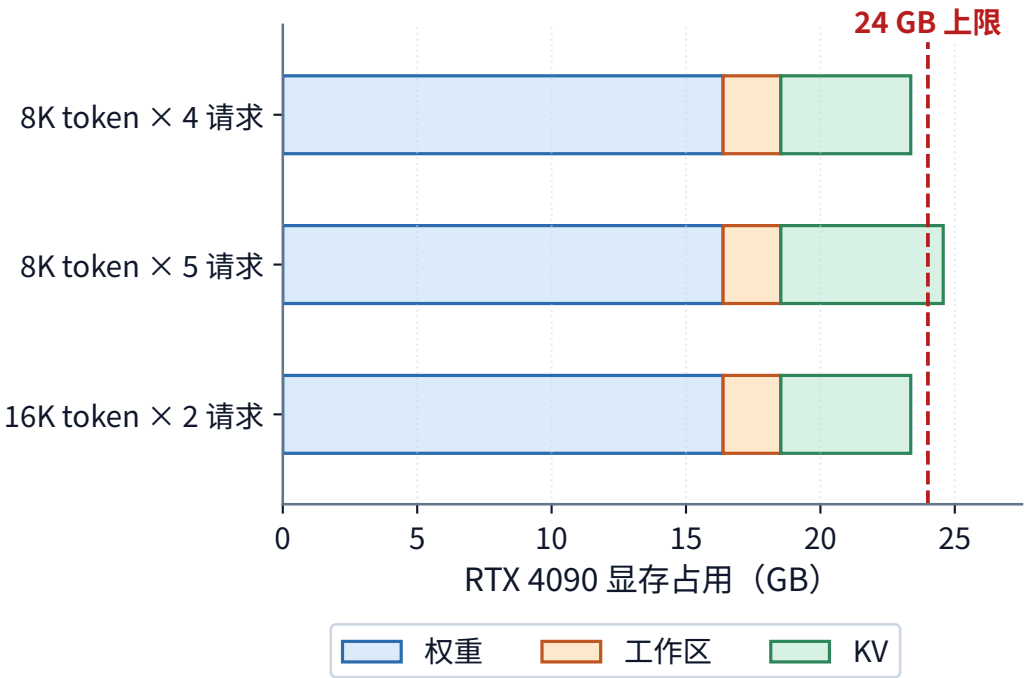
24 GB 上限
8K token × 4 请求
8K token × 5 请求
16K token × 2 请求
0
5
10
15
20
25
RTX 4090 显存占用（GB）
权重
工作区
KV