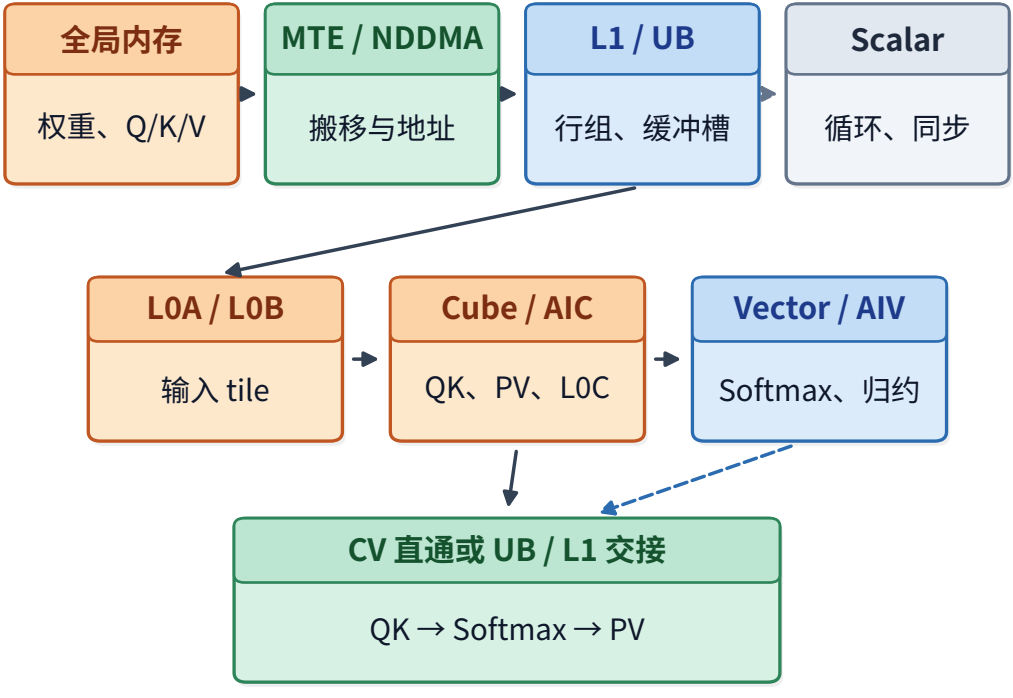
全局内存
权重、Q/K/V
MTE / NDDMA
搬移与地址
L1 / UB
行组、缓冲槽
Scalar
循环、同步
L0A / L0B
输入 tile
Cube / AIC
QK、PV、L0C
Vector / AIV
Softmax、归约
CV 直通或 UB / L1 交接
QK → Softmax → PV