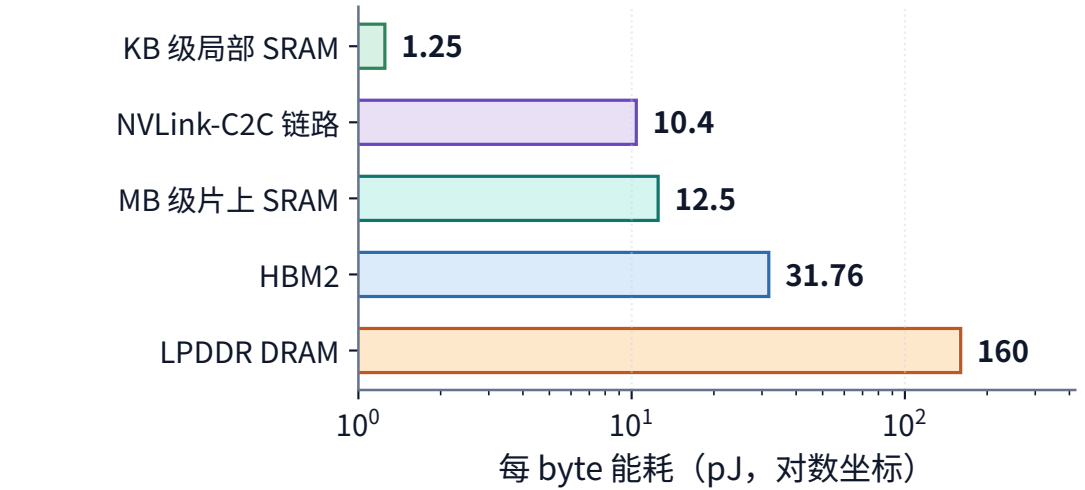
KB 级局部 SRAM
1.25
NVLink-C2C 链路
10.4
MB 级片上 SRAM
12.5
HBM2
31.76
LPDDR DRAM
160
10^0
10^1
10^2
每 byte 能耗（pJ，对数坐标）

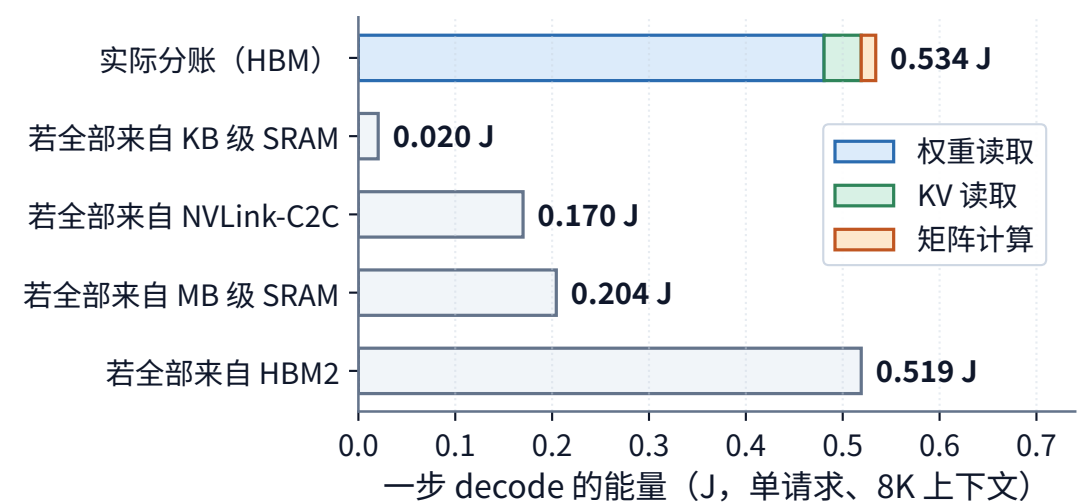
实际分账（HBM）
0.534 J
若全部来自 KB 级 SRAM
0.020 J
若全部来自 NVLink-C2C
0.170 J
若全部来自 MB 级 SRAM
0.204 J
若全部来自 HBM2
0.519 J
权重读取
KV 读取
矩阵计算
0.0
0.1
0.2
0.3
0.4
0.5
0.6
0.7
一步 decode 的能量（J，单请求、8K 上下文）