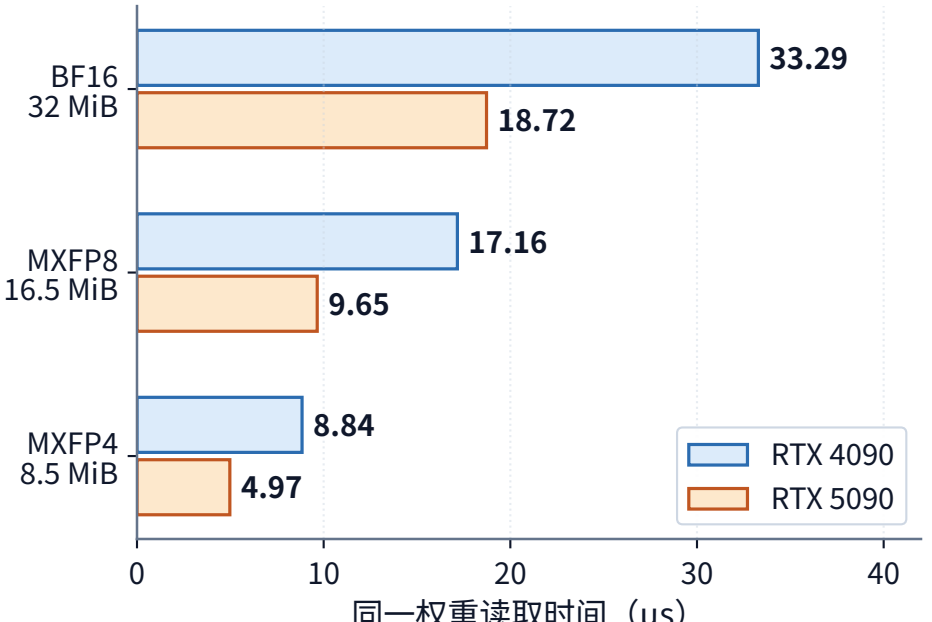
BF16
32 MiB
33.29
18.72
MXFP8
16.5 MiB
17.16
9.65
MXFP4
8.5 MiB
8.84
4.97
RTX 4090
RTX 5090
0
10
20
30
40
同一权重读取时间（μs）