计算放到权重所在的 die

HGX B200

两侧各读本地权重：8.6 ms

昇腾 910C

两侧各读本地权重：21.5 ms