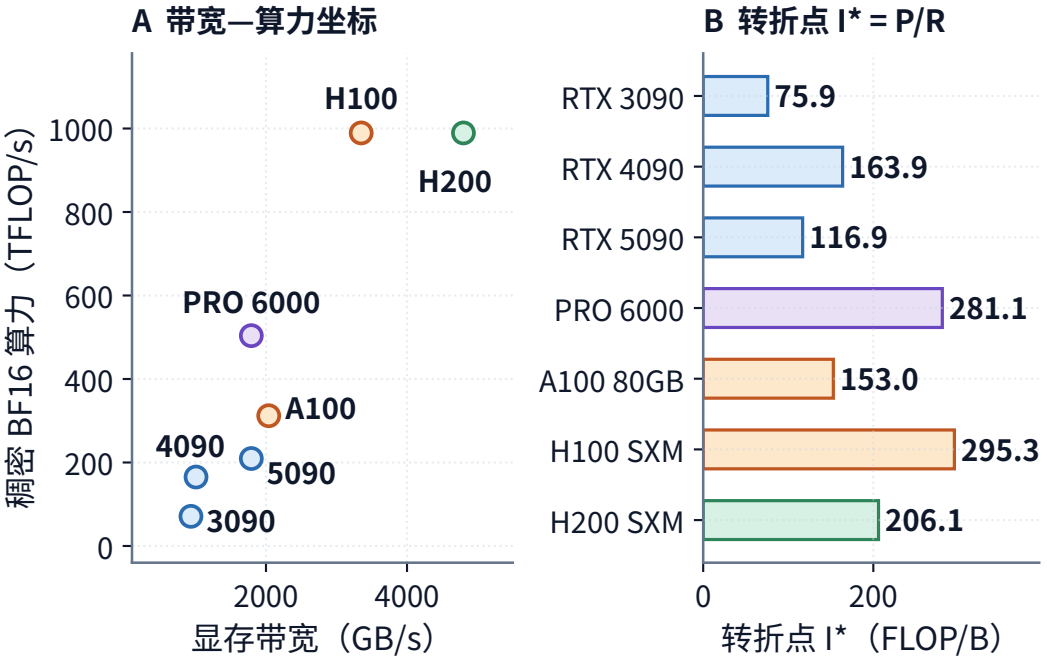
A 带宽—算力坐标
稠密 BF16 算力（TFLOP/s）
显存带宽（GB/s）
0
200
400
600
800
1000
2000
4000
H100
H200
PRO 6000
A100
4090
5090
3090
B 转折点 I* = P/R
RTX 3090
RTX 4090
RTX 5090
PRO 6000
A100 80GB
H100 SXM
H200 SXM
75.9
163.9
116.9
281.1
153.0
295.3
206.1
0
200
转折点 I*（FLOP/B）