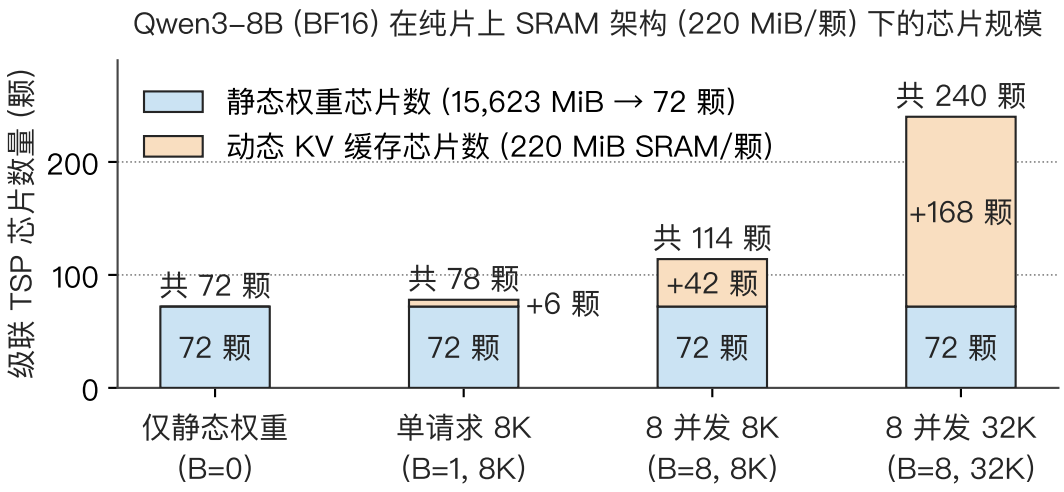
Qwen3–8B (BF16) 在纯片上 SRAM 架构 (220 MiB/颗) 下的芯片规模
级联 TSP 芯片数量 (颗)
静态权重芯片数 (15,623 MiB → 72 颗)
动态 KV 缓存芯片数 (220 MiB SRAM/颗)
200
100
0
共 72 颗
72 颗
共 78 颗
+6 颗
72 颗
共 114 颗
+42 颗
72 颗
共 240 颗
+168 颗
72 颗
仅静态权重
(B=0)
单请求 8K
(B=1, 8K)
8 并发 8K
(B=8, 8K)
8 并发 32K
(B=8, 32K)