
A. DeepGEMM 细粒度 FP8 两级累加与运行时 JIT
细粒度 FP8
激活 1×128
权重 128×128
1. 矩阵核
K_b=128 步
免尾数截断
2. CUDA 核
FP32 累加
每块恢复精度
JIT 特化（~300 行模板）
动态 M 编码为立即数常量
尾块展开+TMA 多播择优
省体积，提速 1.3x–2.7x
块级原语：ThunderKittens 2.0（16×16）与 TileLang
将双缓冲与两级累加浓缩至数十行可移植代码
B. GraCE（ASPLOS '26）跨分支整图捕获与权衡
传统分段图（Graph Break）
动态分支回退主机 CPU
暴露数十 μs 发射空泡
GraCE 编译器重写（谓词）
分支转 GPU 条件节点
跨分支拼接端到端整图
运行时净收益
消除子图间主机发射空泡
小批量与 Agent 尾延迟收敛
显式工程代价（实测）
图编译构建耗时 +66%
静态并集使峰值显存 +20%
准则：显存充裕、延迟敏感的解码开启整图合并
显存受限或形状跳变的预填充用分段图+计划复用