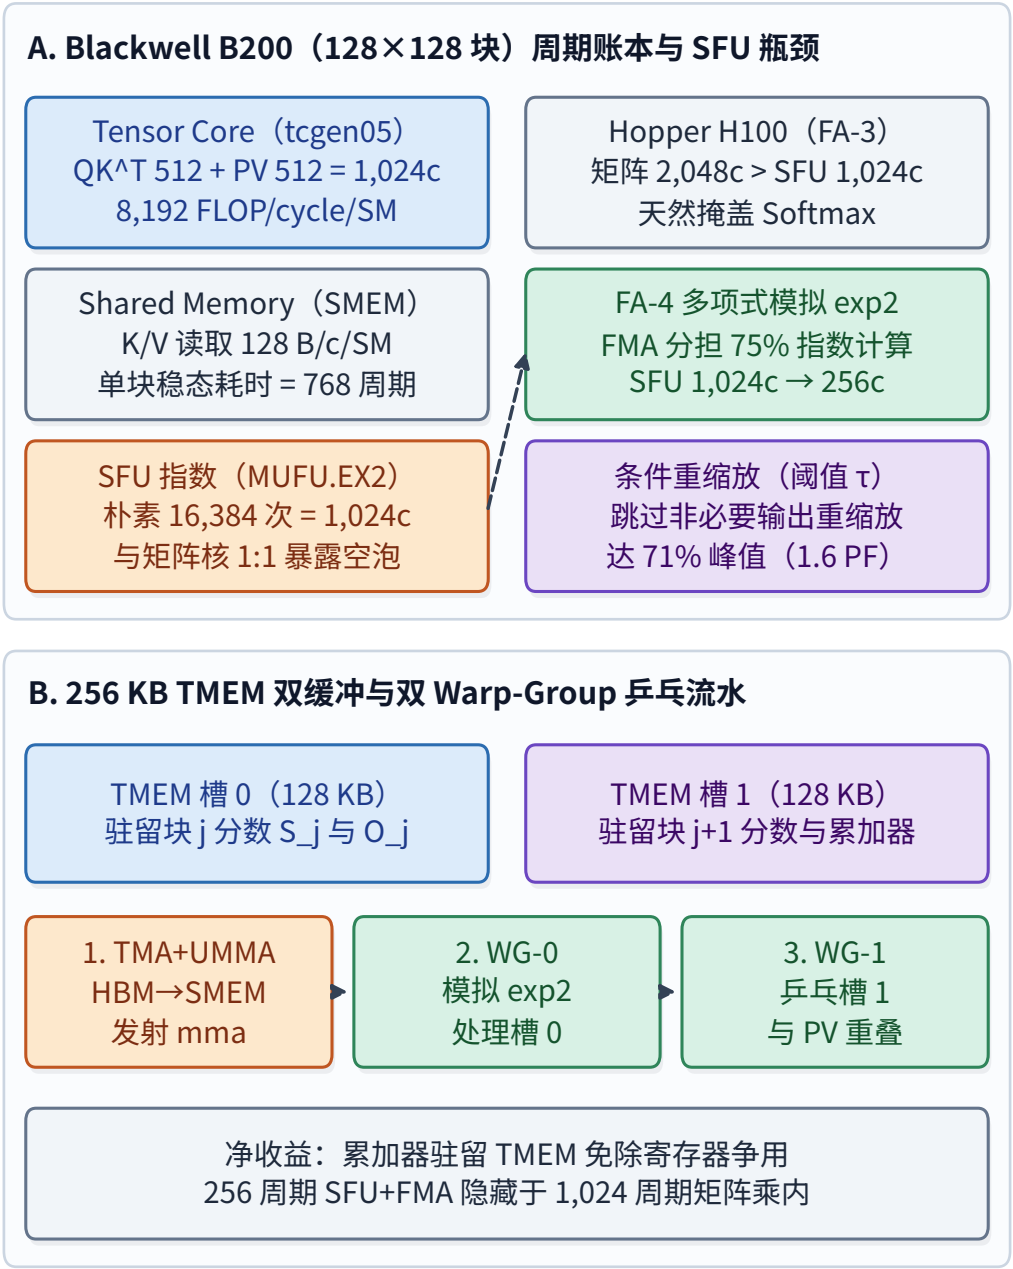
A. Blackwell B200（128×128 块）周期账本与 SFU 瓶颈
Tensor Core（tcgen05）
QK^T 512 + PV 512 = 1,024c
8,192 FLOP/cycle/SM
Hopper H100（FA-3）
矩阵 2,048c > SFU 1,024c
天然掩盖 Softmax
Shared Memory（SMEM）
K/V 读取 128 B/c/SM
单块稳态耗时 = 768 周期
FA-4 多项式模拟 exp2
FMA 分担 75% 指数计算
SFU 1,024c → 256c
SFU 指数（MUFU.EX2）
朴素 16,384 次 = 1,024c
与矩阵核 1:1 暴露空泡
条件重缩放（阈值 τ）
跳过非必要输出重缩放
达 71% 峰值（1.6 PF）
B. 256 KB TMEM 双缓冲与双 Warp-Group 乒乓流水
TMEM 槽 0（128 KB）
驻留块 j 分数 S_j 与 O_j
TMEM 槽 1（128 KB）
驻留块 j+1 分数与累加器
1. TMA+UMMA
HBM→SMEM
发射 mma
2. WG-0
模拟 exp2
处理槽 0
3. WG-1
乒乓槽 1
与 PV 重叠
净收益：累加器驻留 TMEM 免除寄存器争用
256 周期 SFU+FMA 隐藏于 1,024 周期矩阵乘内