A. FlashInfer plan/run 分离与跨层计划复用

逐层独立 plan（36 层）
主机 36×20 = 720 µs
144 次 H2D · 2.0~2.4 ms

1. CPU plan
序列长+页表
切分均衡任务

2. 显存计划表
单次 H2D 写入
工作区常驻

同构共享 1 次 plan
主机 1×20 = 20 µs（省 700 µs）
4 次 H2D · 0.72~0.75 ms

3. GPU run：第 0..35 层注意力
复读同一计划表（开销降 ~3×）

异构模型按族 plan
MLA + SWA/KDA 分 2 族
每步 2×20 = 40 µs

失效边界：下一步长度+1 或批增减
必须重跑 plan 刷新页表与切分

B. RL 训推切换：虚拟地址保留与两级休眠权衡

cuMemAddressReserve 锁地址
CUDA Graph 指针始终合法

Level 1 休眠（卸载至 CPU 内存）
15.26 GiB 迁出+迁回（25 GB/s）
双向搬移耗时 ≈ 1.31 s

休眠 Unmap
释放物理 HBM
39.26 GiB

唤醒 Map
重挂物理 HBM
原虚拟址恢复

Level 2 休眠（直接丢弃权重/KV）
省去 CPU 往返备份（0 s 搬移）
唤醒后训练器原地覆写新权重

收益：释放 39.26 GiB 供训练
零重录 100% 保活 CUDA Graph

工程边界：Level 2 省 1.31 s/轮
未训 MTP/LoRA 需单独保留