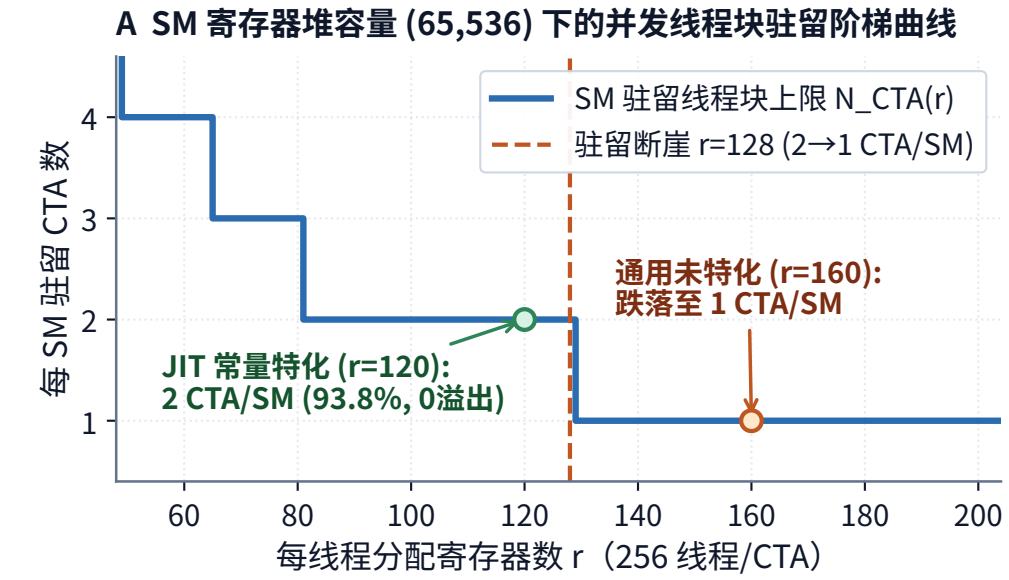
A SM 寄存器堆容量 (65,536) 下的并发线程块驻留阶梯曲线
SM 驻留线程块上限 N_CTA(r)
驻留断崖 r=128 (2→1 CTA/SM)
每 SM 驻留 CTA 数
4
3
2
1
通用未特化 (r=160):
跌落至 1 CTA/SM
JIT 常量特化 (r=120):
2 CTA/SM (93.8%, 0溢出)
60
80
100
120
140
160
180
200
每线程分配寄存器数 r（256 线程/CTA）

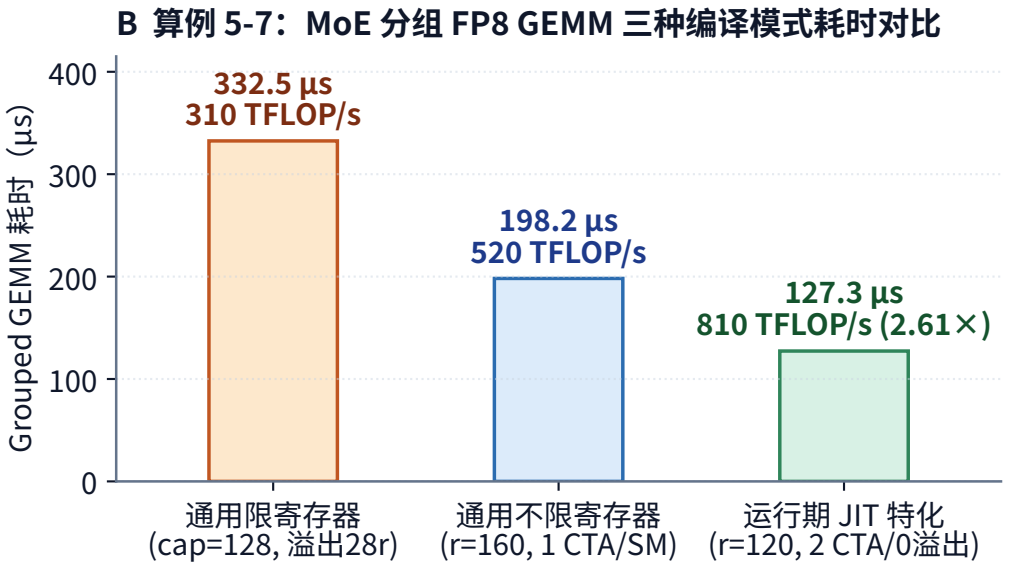
B 算例 5-7：MoE 分组 FP8 GEMM 三种编译模式耗时对比
Grouped GEMM 耗时（μs）
400
300
200
100
0
332.5 μs
310 TFLOP/s
198.2 μs
520 TFLOP/s
127.3 μs
810 TFLOP/s (2.61×)
通用限寄存器
(cap=128, 溢出28r)
通用不限寄存器
(r=160, 1 CTA/SM)
运行期 JIT 特化
(r=120, 2 CTA/0溢出)