A. Mirage 三级代数张量超优化与有限域 F_p 等价验证

1. 内核图 KGraph
跨算子代数重写
融合归约与投影

→

2. 块图 TBGraph
共享内存分块
免全局显存落地

→

3. 线程图 TGraph
寄存器指令合成
F_p 等价验证

代数融合：将 RMSNorm 归约折叠进前驱投影尾声，免去 HBM 往返

验证完备性：有限域 F_p 随机指纹测试，毫秒级判定代数等价

B. 算例 5-5 / 实验 5-16：80 层模型（720 算子）单步解码耗时对比

Eager 逐算子
计算 4.80+启动 2.52
总计 8.80 ms

→

CUDA Graph
启动压至 0.08ms
总计 6.30 ms

→

Mirage MPK
计算 4.80+队列 0.18
总计 4.98 ms

SM 角色特化（132 SM）
112 计算 SM + 20 通信 SM

片上 L2 / SMEM 任务队列
消除 720 道全局栅栏与尾波

净收益：MPK 较 Eager 快 1.77×（省 3.82ms），较 Graph 省 1.32ms