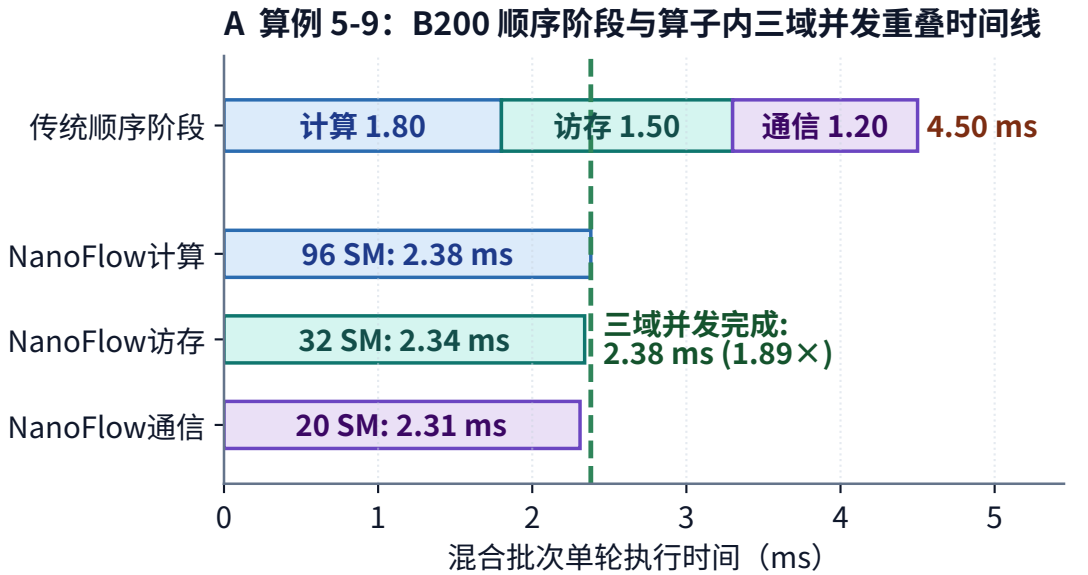
A 算例 5-9：B200 顺序阶段与算子内三域并发重叠时间线
传统顺序阶段
计算 1.80
访存 1.50
通信 1.20
4.50 ms
NanoFlow计算
96 SM: 2.38 ms
NanoFlow访存
32 SM: 2.34 ms
三域并发完成:
2.38 ms (1.89×)
NanoFlow通信
20 SM: 2.31 ms
0
1
2
3
4
5
混合批次单轮执行时间（ms）

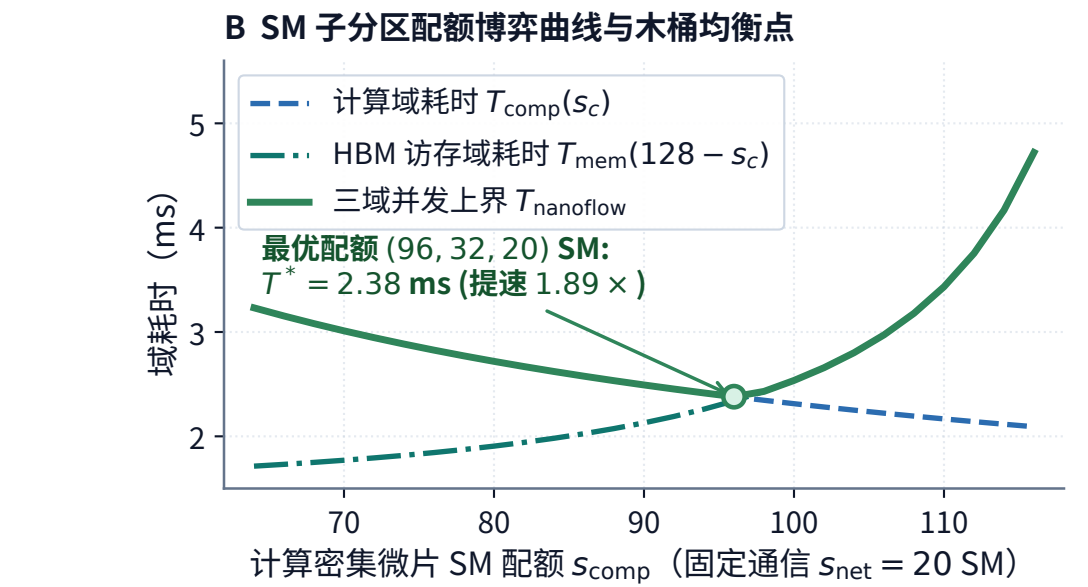
B SM 子分区配额博弈曲线与木桶均衡点
计算域耗时 $T_{comp}(s_c)$
HBM 访存域耗时 $T_{mem}(128 - s_c)$
三域并发上界 $T_{nanoflow}$
最优配额 (96, 32, 20) SM:
T^* = 2.38 ms (提速 1.89 ×)
域耗时（ms）
2
3
4
5
70
80
90
100
110
计算密集微片 SM 配额 s_{comp}（固定通信 s_{net} = 20 SM）