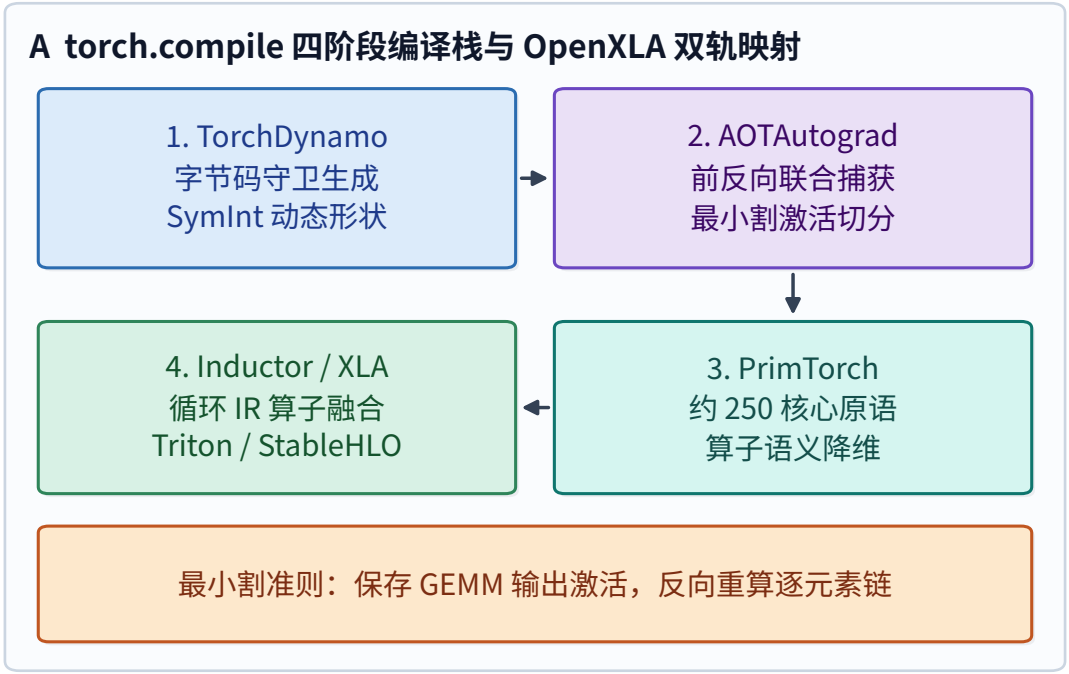
A torch.compile 四阶段编译栈与 OpenXLA 双轨映射
1. TorchDynamo
字节码守卫生成
SymInt 动态形状
2. AOTAutograd
前反向联合捕获
最小割激活切分
3. PrimTorch
约 250 核心原语
算子语义降维
4. Inductor / XLA
循环 IR 算子融合
Triton / StableHLO
最小割准则：保存 GEMM 输出激活，反向重算逐元素链

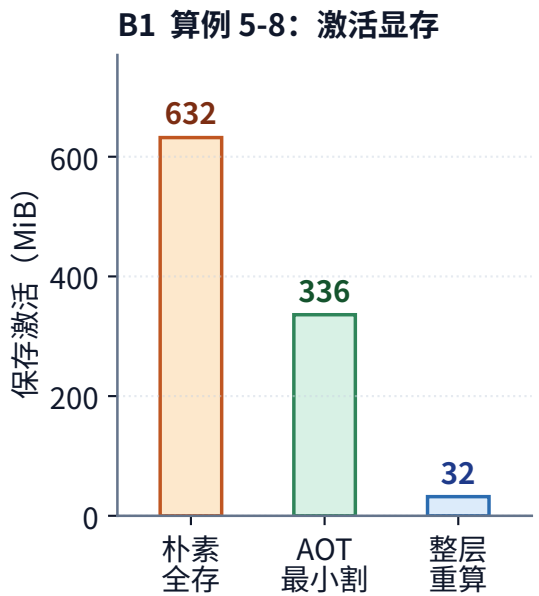
B1 算例 5-8：激活显存
保存激活（MiB）
0
200
400
600
632
336
32
朴素
全存
AOT
最小割
整层
重算

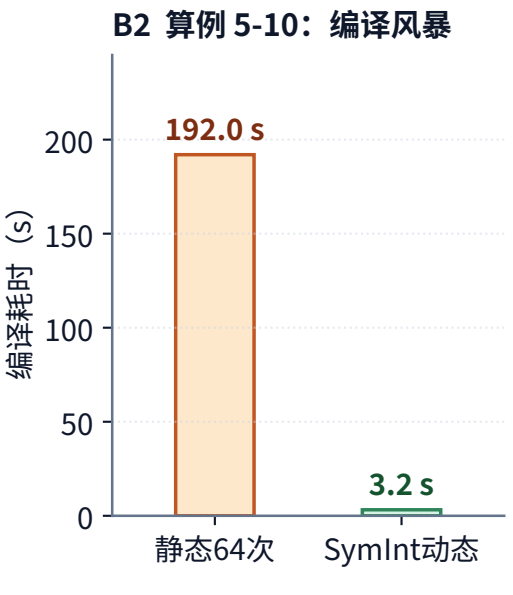
B2 算例 5-10：编译风暴
编译耗时（s）
0
50
100
150
200
192.0 s
3.2 s
静态64次
SymInt动态