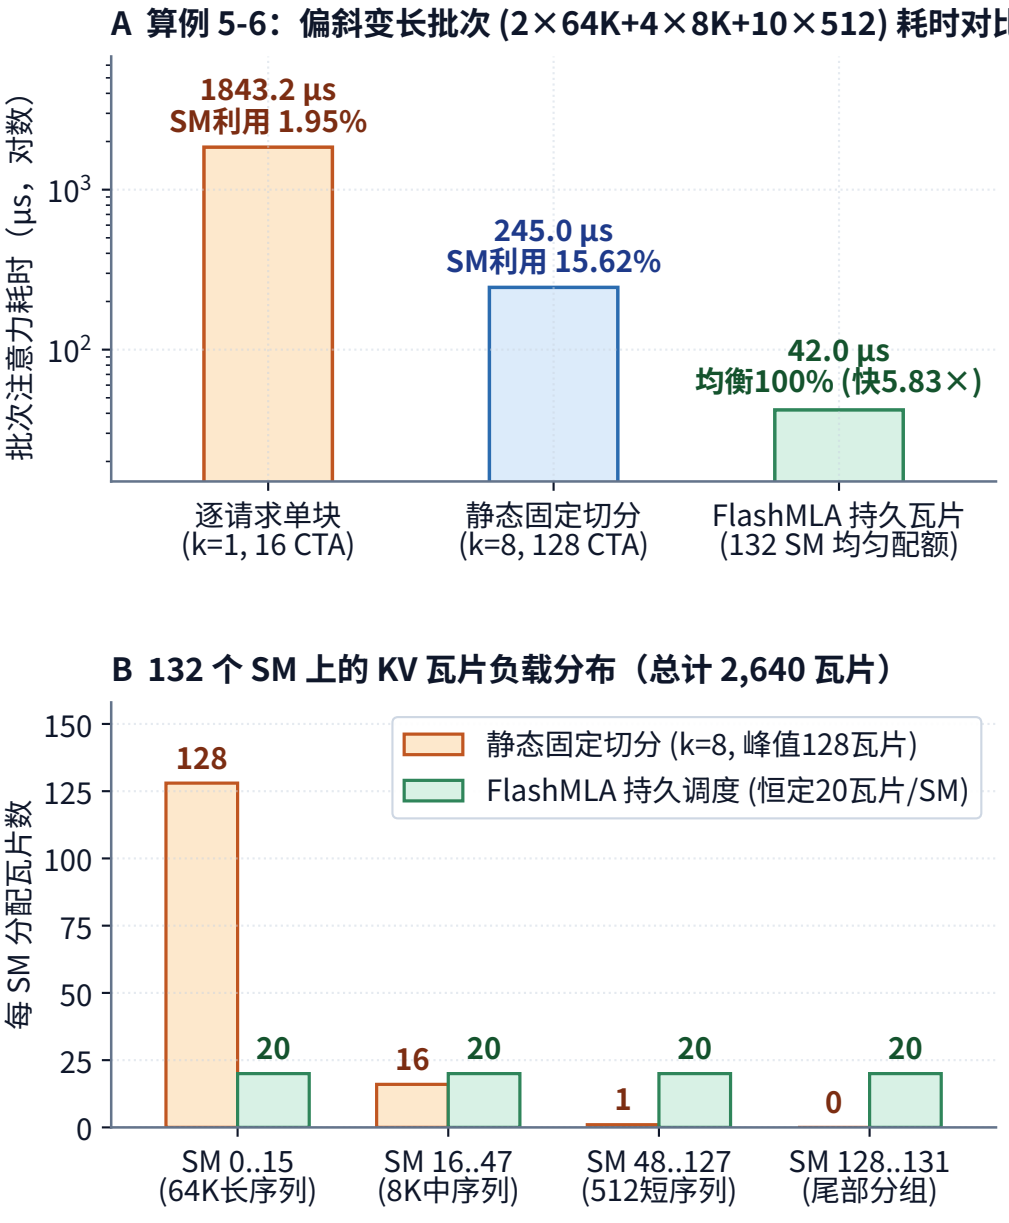
A 算例 5-6：偏斜变长批次 (2×64K+4×8K+10×512) 耗时对比
批次注意力耗时（μs，对数）
10^3
10^2
1843.2 μs
SM利用 1.95%
245.0 μs
SM利用 15.62%
42.0 μs
均衡100% (快5.83×)
逐请求单块
(k=1, 16 CTA)
静态固定切分
(k=8, 128 CTA)
FlashMLA 持久瓦片
(132 SM 均匀配额)
B 132 个 SM 上的 KV 瓦片负载分布（总计 2,640 瓦片）
每 SM 分配瓦片数
150
125
100
75
50
25
0
静态固定切分 (k=8, 峰值128瓦片)
FlashMLA 持久调度 (恒定20瓦片/SM)
128
20
16
20
1
20
0
20
SM 0..15
(64K长序列)
SM 16..47
(8K中序列)
SM 48..127
(512短序列)
SM 128..131
(尾部分组)