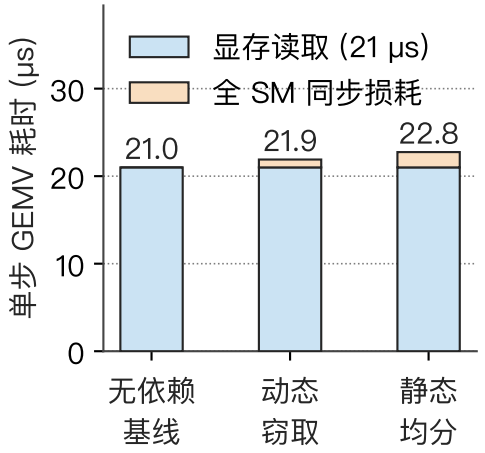
(a) 4096×4096 投影总耗时
显存读取 (21 μs)
全 SM 同步损耗
单步 GEMV 耗时 (μs)
0
10
20
30
21.0
21.9
22.8
无依赖
基线
动态
窃取
静态
均分

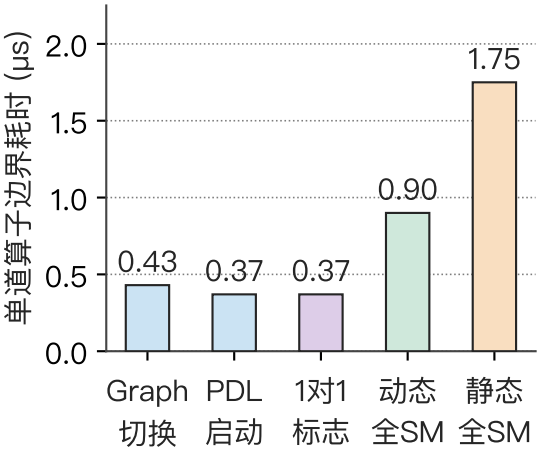
(b) 算子边界切换与全卡同步
单道算子边界耗时 (μs)
0.0
0.5
1.0
1.5
2.0
0.43
0.37
0.37
0.90
1.75
Graph
切换
PDL
启动
1对1
标志
动态
全SM
静态
全SM