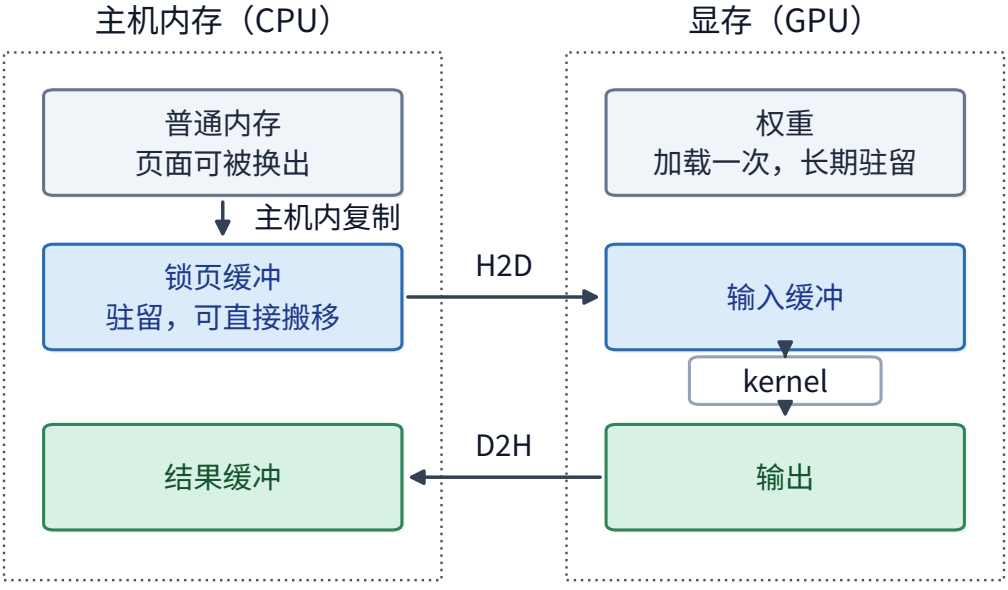
主机内存（CPU）
显存（GPU）
普通内存
页面可被换出
主机内复制
锁页缓冲
驻留，可直接搬移
H2D
权重
加载一次，长期驻留
输入缓冲
kernel
输出
D2H
结果缓冲