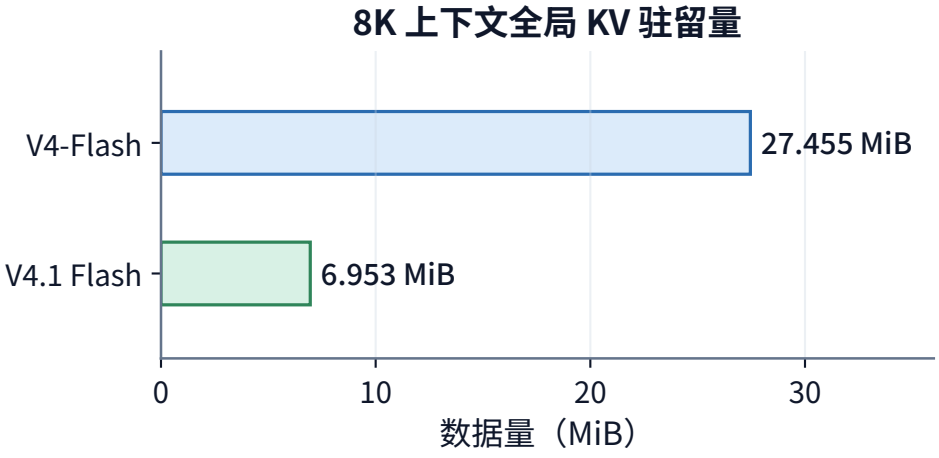
8K 上下文全局 KV 驻留量
V4-Flash
27.455 MiB
V4.1 Flash
6.953 MiB
0
10
20
30
数据量（MiB）

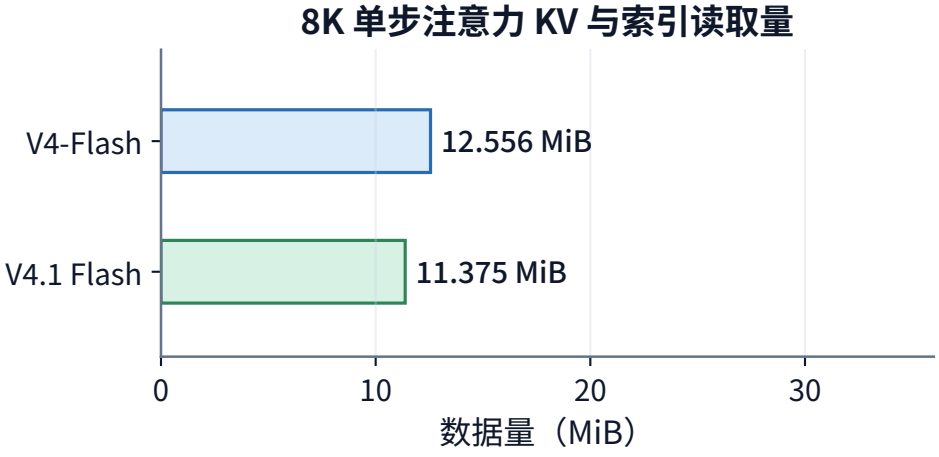
8K 单步注意力 KV 与索引读取量
V4-Flash
12.556 MiB
V4.1 Flash
11.375 MiB
0
10
20
30
数据量（MiB）