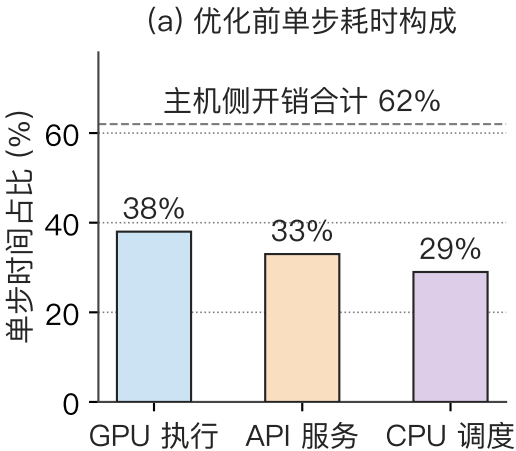
(a) 优化前单步耗时构成
单步时间占比 (%)
0
20
40
60
主机侧开销合计 62%
38%
33%
29%
GPU 执行
API 服务
CPU 调度

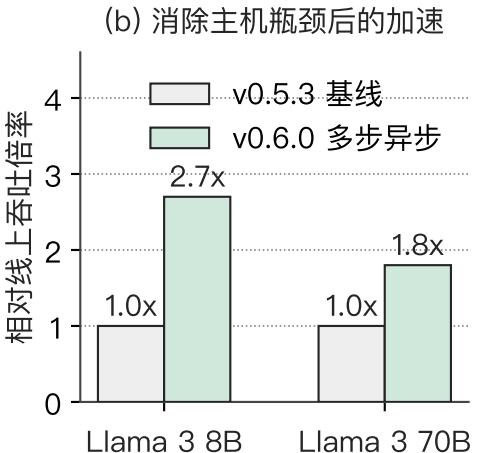
(b) 消除主机瓶颈后的加速
相对线上吞吐倍率
0
1
2
3
4
v0.5.3 基线
v0.6.0 多步异步
1.0x
2.7x
1.0x
1.8x
Llama 3 8B
(H100)
Llama 3 70B
(H100)