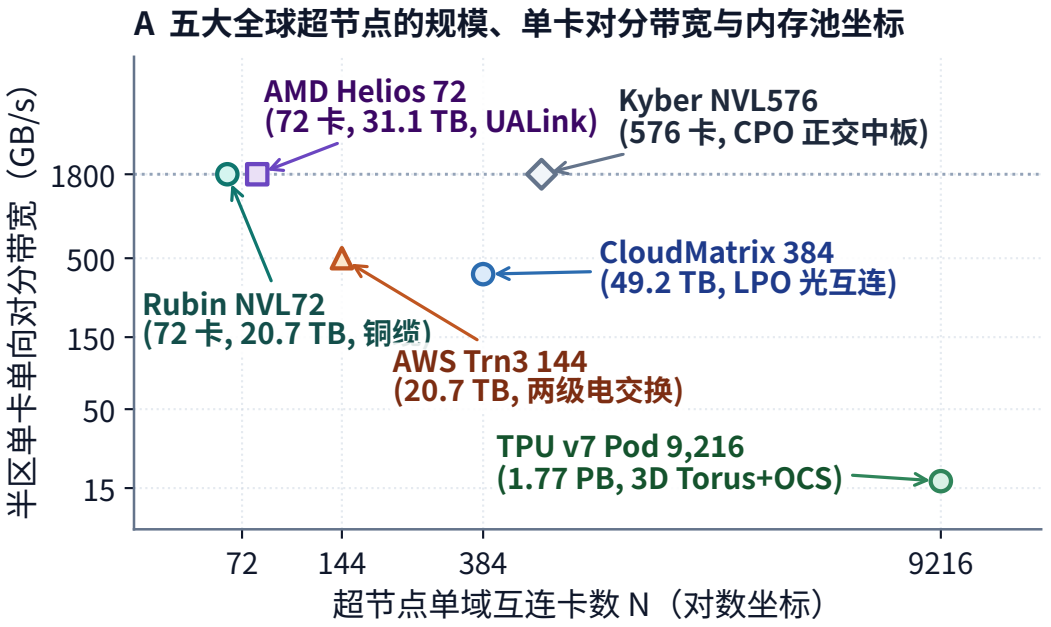
A 五大全球超节点的规模、单卡对分带宽与内存池坐标
半区单卡单向对分带宽（GB/s）
1800
500
150
50
15
AMD Helios 72
(72 卡, 31.1 TB, UALink)
Kyber NVL576
(576 卡, CPO 正交中板)
CloudMatrix 384
(49.2 TB, LPO 光互连)
Rubin NVL72
(72 卡, 20.7 TB, 铜缆)
AWS Trn3 144
(20.7 TB, 两级电交换)
TPU v7 Pod 9,216
(1.77 PB, 3D Torus+OCS)
72
144
384
9216
超节点单域互连卡数 N（对数坐标）

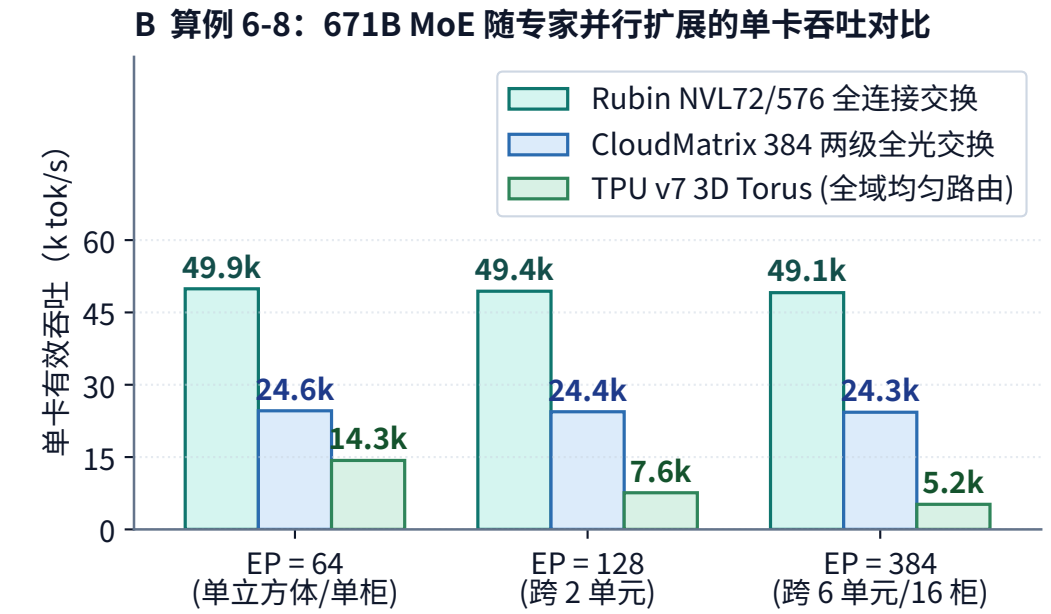
B 算例 6-8：671B MoE 随专家并行扩展的单卡吞吐对比
Rubin NVL72/576 全连接交换
CloudMatrix 384 两级全光交换
TPU v7 3D Torus (全域均匀路由)
单卡有效吞吐（k tok/s）
60
45
30
15
0
49.9k
24.6k
14.3k
49.4k
24.4k
7.6k
49.1k
24.3k
5.2k
EP = 64
(单立方体/单柜)
EP = 128
(跨 2 单元)
EP = 384
(跨 6 单元/16 柜)