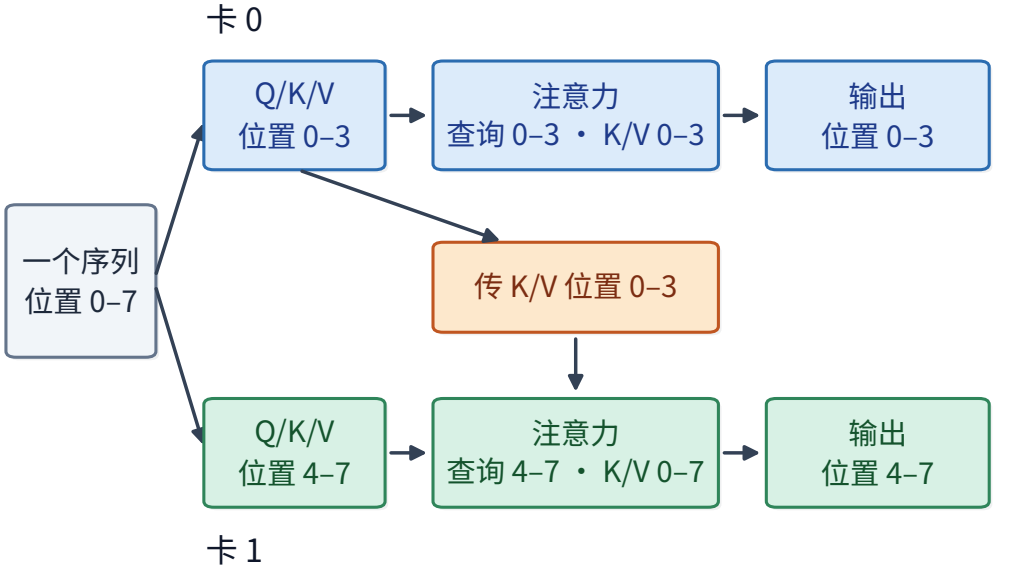
卡 0
Q/K/V
位置 0–3
注意力
查询 0–3 · K/V 0–3
输出
位置 0–3
一个序列
位置 0–7
传 K/V 位置 0–3
Q/K/V
位置 4–7
注意力
查询 4–7 · K/V 0–7
输出
位置 4–7
卡 1