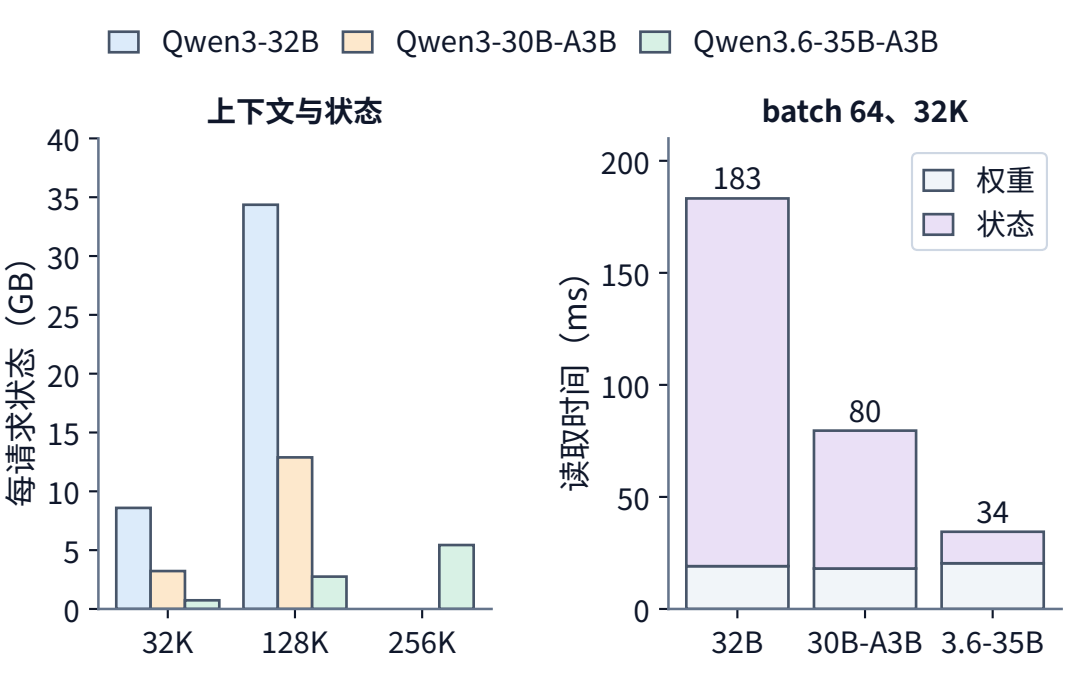
Qwen3-32B
Qwen3-30B-A3B
Qwen3.6-35B-A3B
上下文与状态
每请求状态（GB）
0
5
10
15
20
25
30
35
40
32K
128K
256K
batch 64、32K
读取时间（ms）
0
50
100
150
200
183
80
34
权重
状态
32B
30B-A3B
3.6-35B