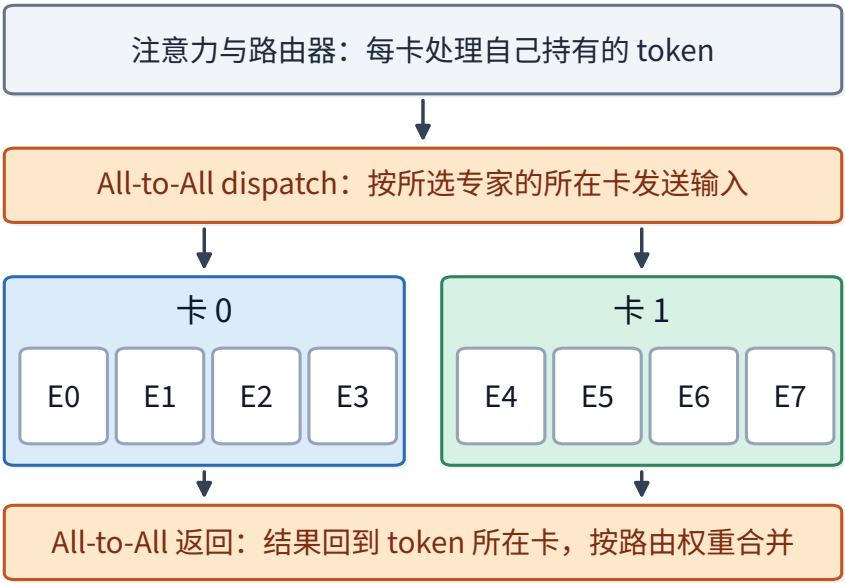
注意力与路由器：每卡处理自己持有的 token
All-to-All dispatch：按所选专家的所在卡发送输入
卡 0
E0
E1
E2
E3
卡 1
E4
E5
E6
E7
All-to-All 返回：结果回到 token 所在卡，按路由权重合并