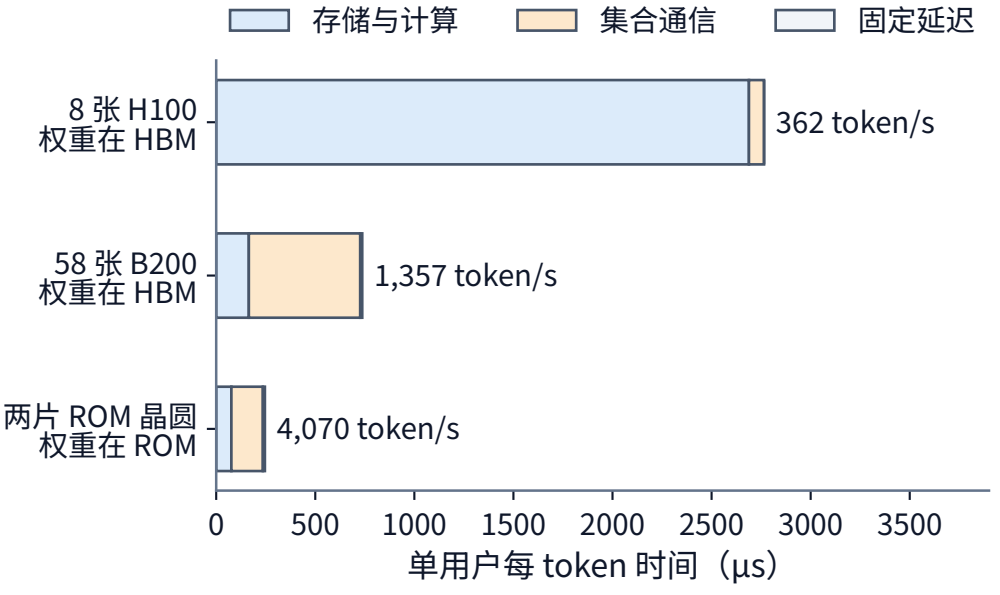
存储与计算
集合通信
固定延迟
8 张 H100
权重在 HBM
362 token/s
58 张 B200
权重在 HBM
1,357 token/s
两片 ROM 晶圆
权重在 ROM
4,070 token/s
0
500
1000
1500
2000
2500
3000
3500
单用户每 token 时间（μs）