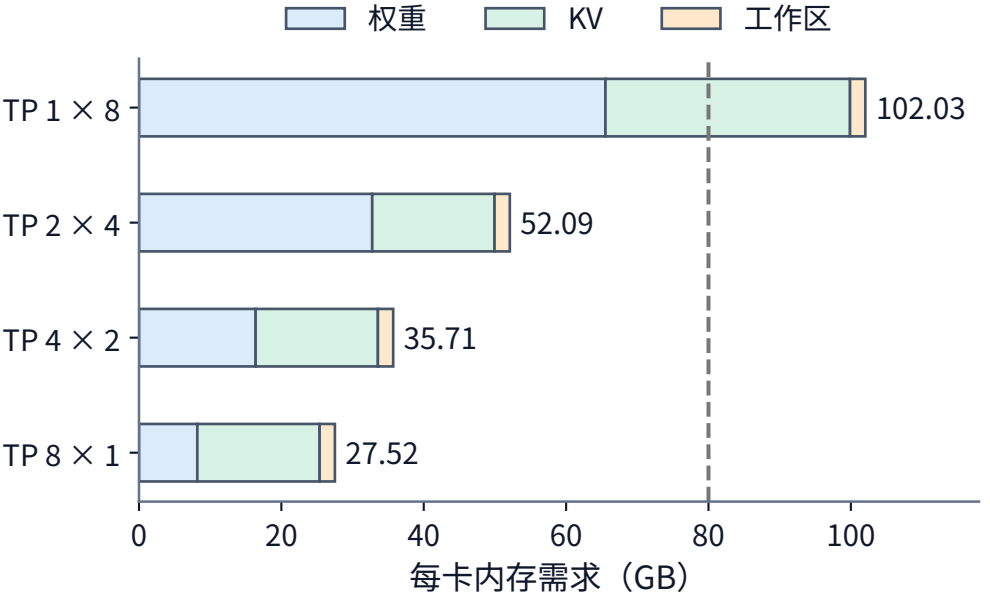
权重
KV
工作区
TP 1 × 8
TP 2 × 4
TP 4 × 2
TP 8 × 1
102.03
52.09
35.71
27.52
0
20
40
60
80
100
每卡内存需求（GB）