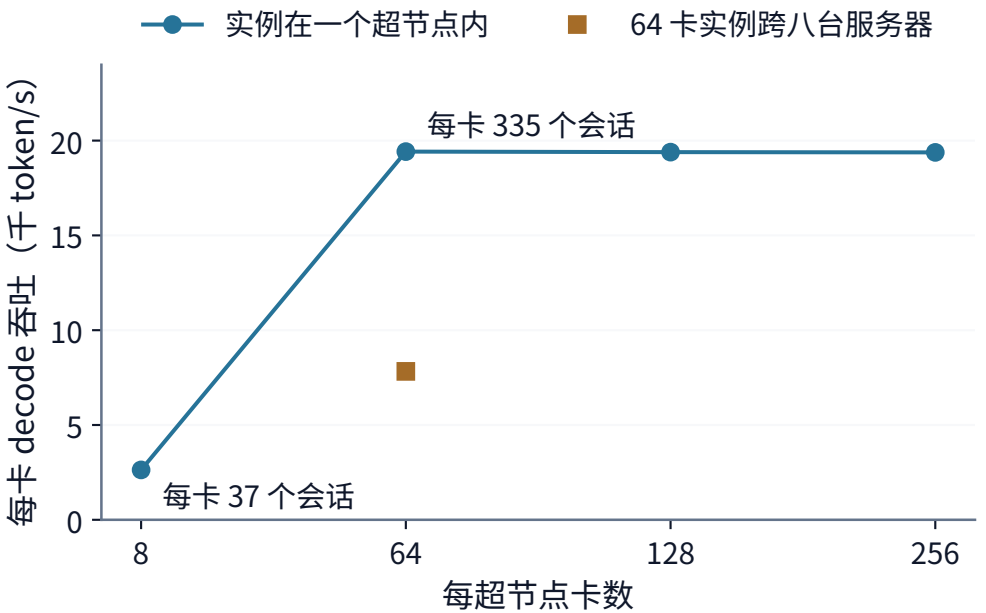
实例在一个超节点内
64 卡实例跨八台服务器
每卡 335 个会话
每卡 37 个会话
每卡 decode 吞吐（千 token/s）
每超节点卡数
0
5
10
15
20
8
64
128
256