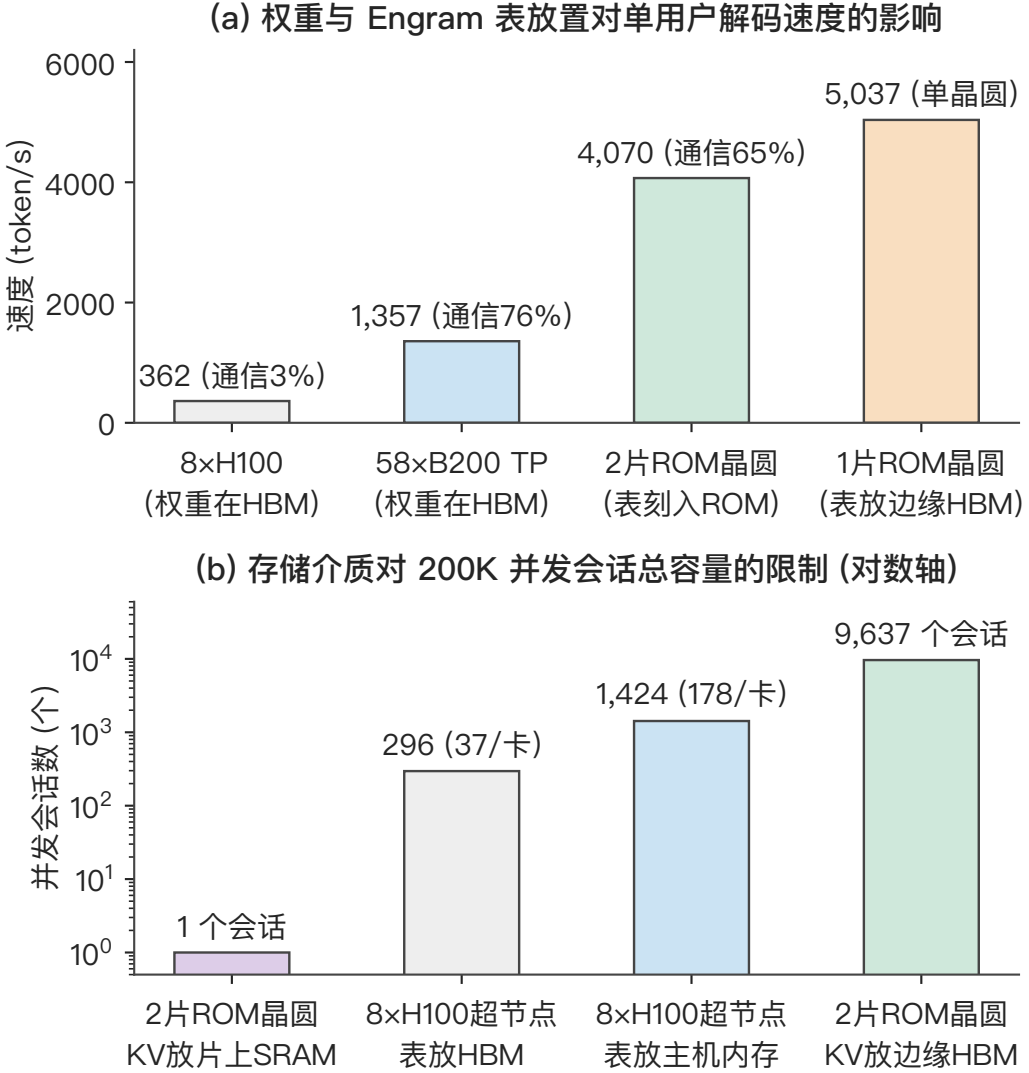
(a) 权重与 Engram 表放置对单用户解码速度的影响
速度 (token/s)
6000
4000
2000
0
362 (通信3%)
1,357 (通信76%)
4,070 (通信65%)
5,037 (单晶圆)
8×H100
(权重在HBM)
58×B200 TP
(权重在HBM)
2片ROM晶圆
(表刻入ROM)
1片ROM晶圆
(表放边缘HBM)
(b) 存储介质对 200K 并发会话总容量的限制 (对数轴)
并发会话数 (个)
10^4
10^3
10^2
10^1
10^0
1 个会话
296 (37/卡)
1,424 (178/卡)
9,637 个会话
2片ROM晶圆
KV放片上SRAM
8×H100超节点
表放HBM
8×H100超节点
表放主机内存
2片ROM晶圆
KV放边缘HBM