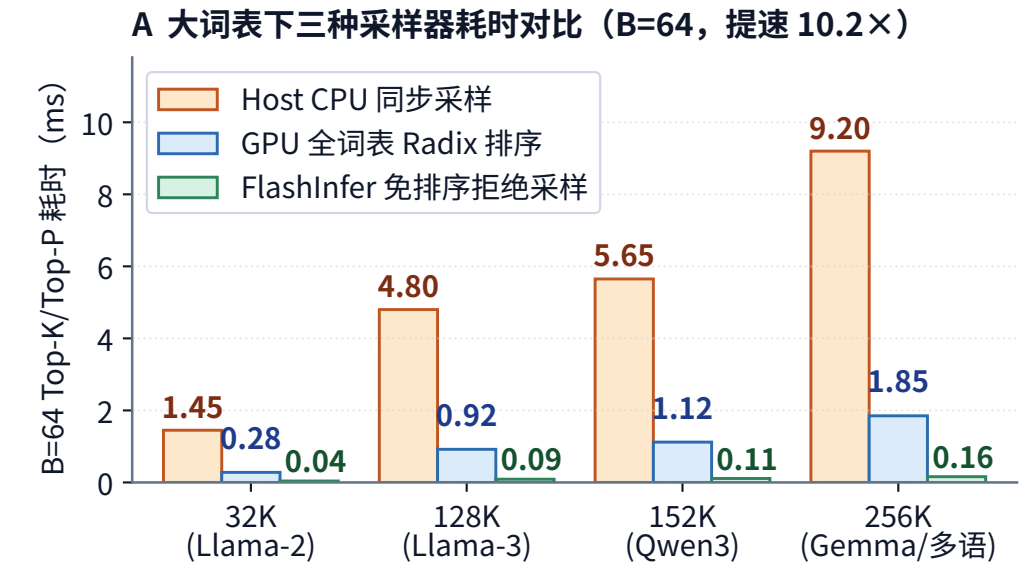
A 大词表下三种采样器耗时对比（B=64，提速 10.2×）
B=64 Top-K/Top-P 耗时（ms）
Host CPU 同步采样
GPU 全词表 Radix 排序
FlashInfer 免排序拒绝采样
0
2
4
6
8
10
1.45
0.28
0.04
4.80
0.92
0.09
5.65
1.12
0.11
9.20
1.85
0.16
32K
(Llama-2)
128K
(Llama-3)
152K
(Qwen3)
256K
(Gemma/多语)

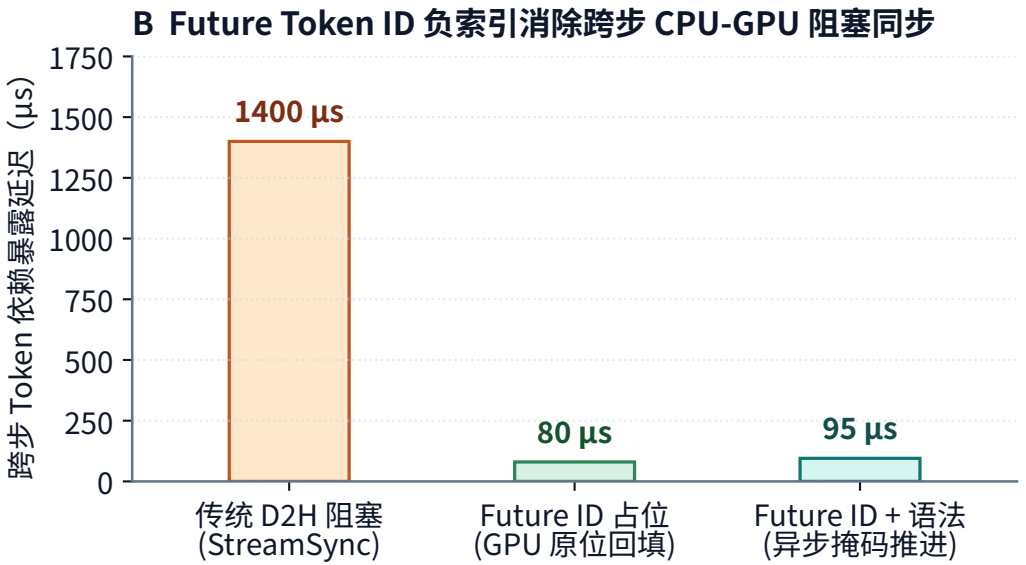
B Future Token ID 负索引消除跨步 CPU-GPU 阻塞同步
跨步 Token 依赖暴露延迟（μs）
0
250
500
750
1000
1250
1500
1750
1400 μs
80 μs
95 μs
传统 D2H 阻塞
(StreamSync)
Future ID 占位
(GPU 原位回填)
Future ID + 语法
(异步掩码推进)