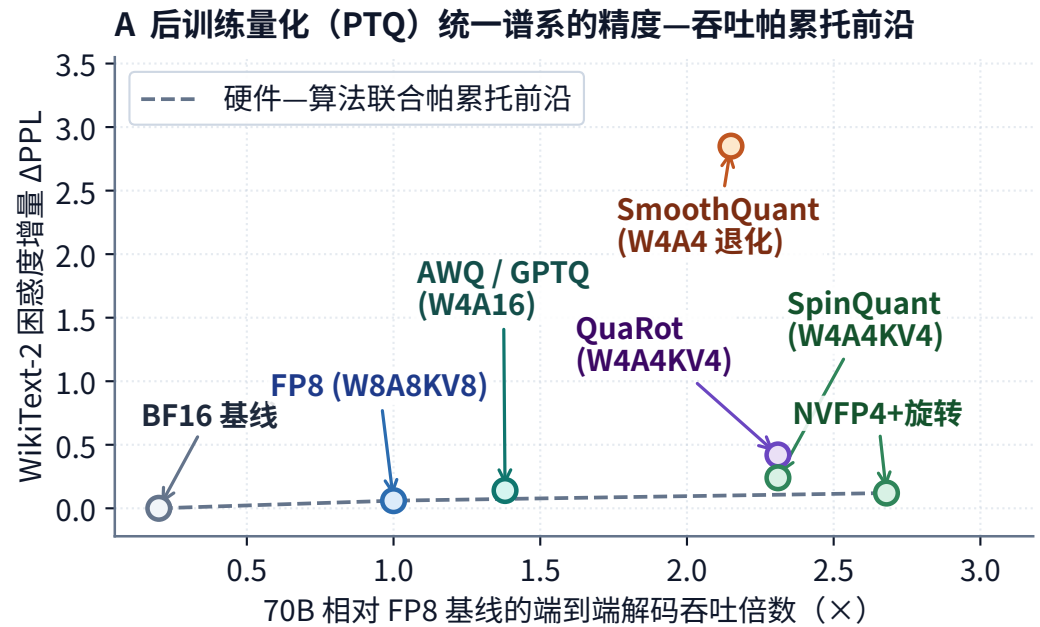
A 后训练量化（PTQ）统一谱系的精度—吞吐帕累托前沿
硬件—算法联合帕累托前沿
WikiText-2 困惑度增量 ΔPPL
3.5
3.0
2.5
2.0
1.5
1.0
0.5
0.0
SmoothQuant
(W4A4 退化)
AWQ / GPTQ
(W4A16)
SpinQuant
(W4A4KV4)
QuaRot
(W4A4KV4)
FP8 (W8A8KV8)
BF16 基线
NVFP4+旋转
0.5
1.0
1.5
2.0
2.5
3.0
70B 相对 FP8 基线的端到端解码吞吐倍数（×）

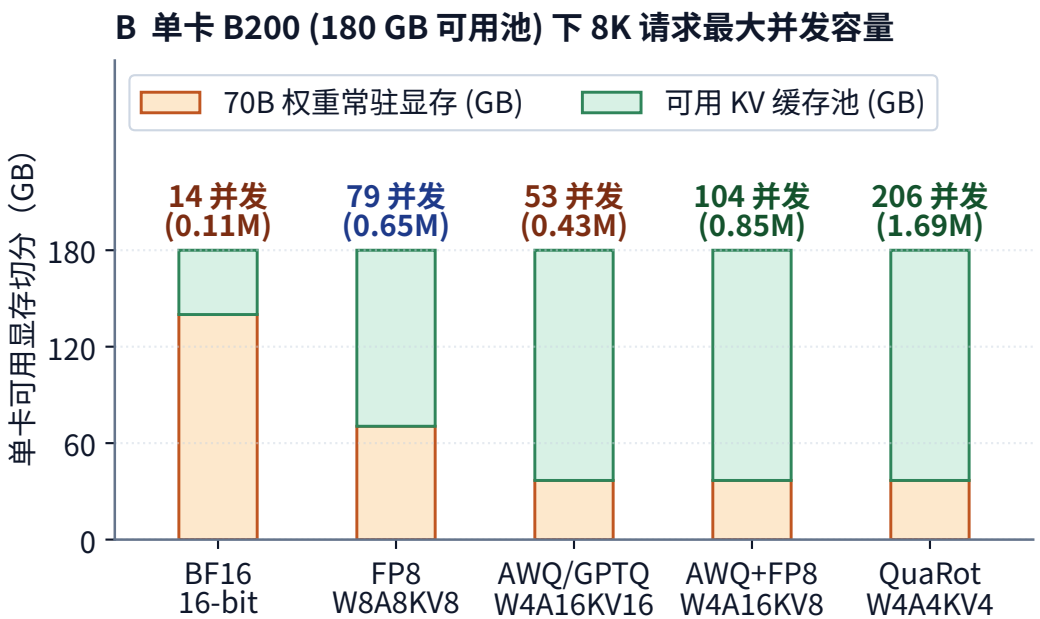
B 单卡 B200 (180 GB 可用池) 下 8K 请求最大并发容量
70B 权重常驻显存 (GB)
可用 KV 缓存池 (GB)
单卡可用显存切分（GB）
14 并发
(0.11M)
79 并发
(0.65M)
53 并发
(0.43M)
104 并发
(0.85M)
206 并发
(1.69M)
180
120
60
0
BF16
16-bit
FP8
W8A8KV8
AWQ/GPTQ
W4A16KV16
AWQ+FP8
W4A16KV8
QuaRot
W4A4KV4