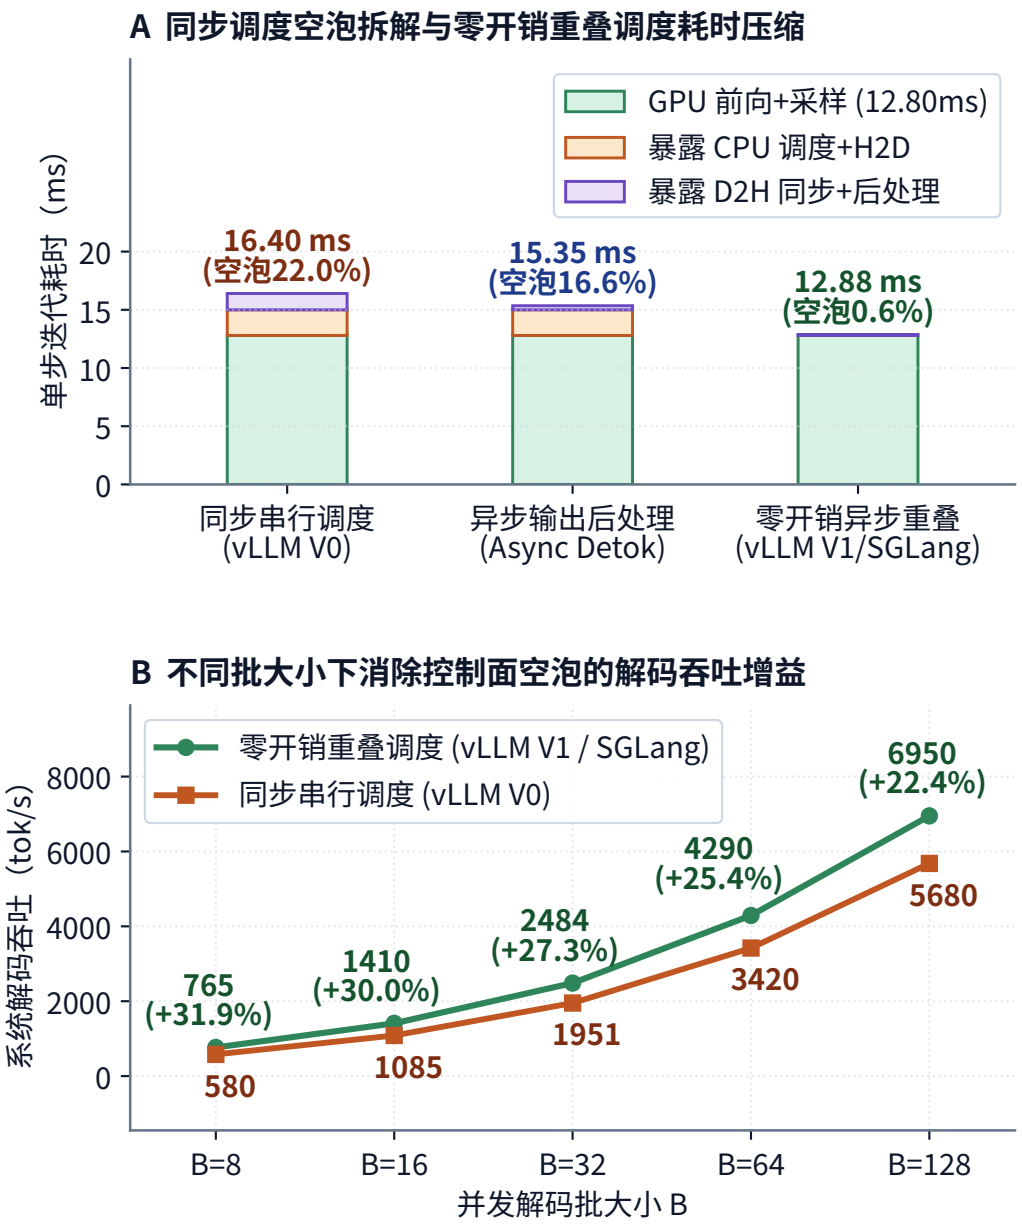
A 同步调度空泡拆解与零开销重叠调度耗时压缩
GPU 前向+采样 (12.80ms)
暴露 CPU 调度+H2D
暴露 D2H 同步+后处理
单步迭代耗时（ms）
0
5
10
15
20
16.40 ms
(空泡22.0%)
15.35 ms
(空泡16.6%)
12.88 ms
(空泡0.6%)
同步串行调度
(vLLM V0)
异步输出后处理
(Async Detok)
零开销异步重叠
(vLLM V1/SGLang)
B 不同批大小下消除控制面空泡的解码吞吐增益
零开销重叠调度 (vLLM V1 / SGLang)
同步串行调度 (vLLM V0)
系统解码吞吐（tok/s）
0
2000
4000
6000
8000
765
(+31.9%)
580
1410
(+30.0%)
1085
2484
(+27.3%)
1951
4290
(+25.4%)
3420
6950
(+22.4%)
5680
B=8
B=16
B=32
B=64
B=128
并发解码批大小 B