A. 结构化生成（XGrammar）CPU-GPU 流水重叠与单步耗时（Qwen3-8B）

串行未重叠 合计 5.2 ms	GPU 前向 2.0 ms	CPU 单线程掩码 3.2 ms 阻塞等待
单线程重叠 合计 3.2 ms	CPU 掩码 3.2 ms 掩盖 GPU 2.0 ms	受限于 CPU 3.2 ms
多线程重叠 合计 2.0 ms	GPU 前向 2.0 ms 掩盖 4 线程 0.8 ms	零掩码阻塞 2.0 ms

位图掩码 1.159 MiB（传输 48.6 µs）；融合采样省去 74.2 MiB Logits 读写

B. 有损 KV 压缩下“单步提速 20% 但输出膨胀 50%”引发耗时反转

BF16 无损基线 50 tok/s · 200 tok	Prefill 0.5 s + Decode 4.0 s	总耗时 4.5 s
有损 KV 压缩 60 tok/s · 300 tok	Prefill 0.5 s + Decode 5.0 s	5.5 s (+22.2%)