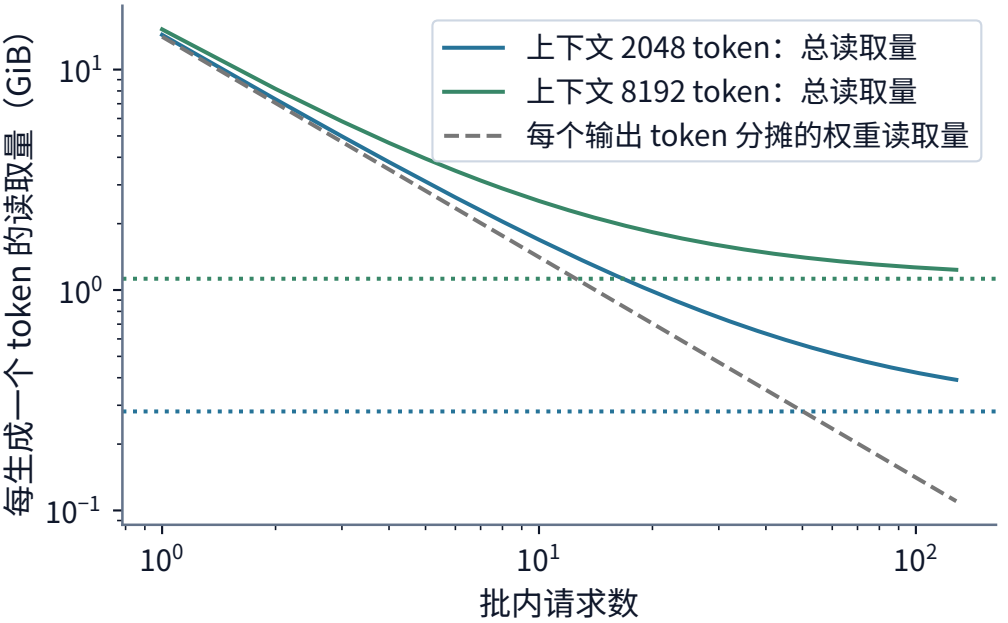
上下文 2048 token：总读取量
上下文 8192 token：总读取量
每个输出 token 分摊的权重读取量
每生成一个 token 的读取量（GiB）
10^{1}
10^{0}
10^{-1}
10^{0}
10^{1}
10^{2}
批内请求数