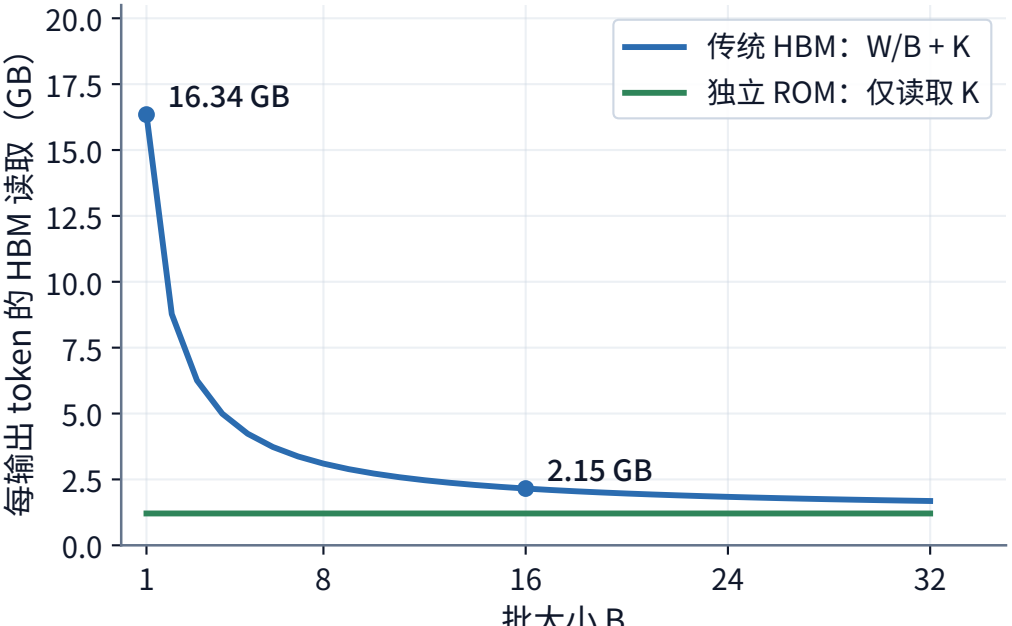
传统 HBM：W/B + K
独立 ROM：仅读取 K
16.34 GB
2.15 GB
每输出 token 的 HBM 读取（GB）
批大小 B
0.0
2.5
5.0
7.5
10.0
12.5
15.0
17.5
20.0
1
8
16
24
32