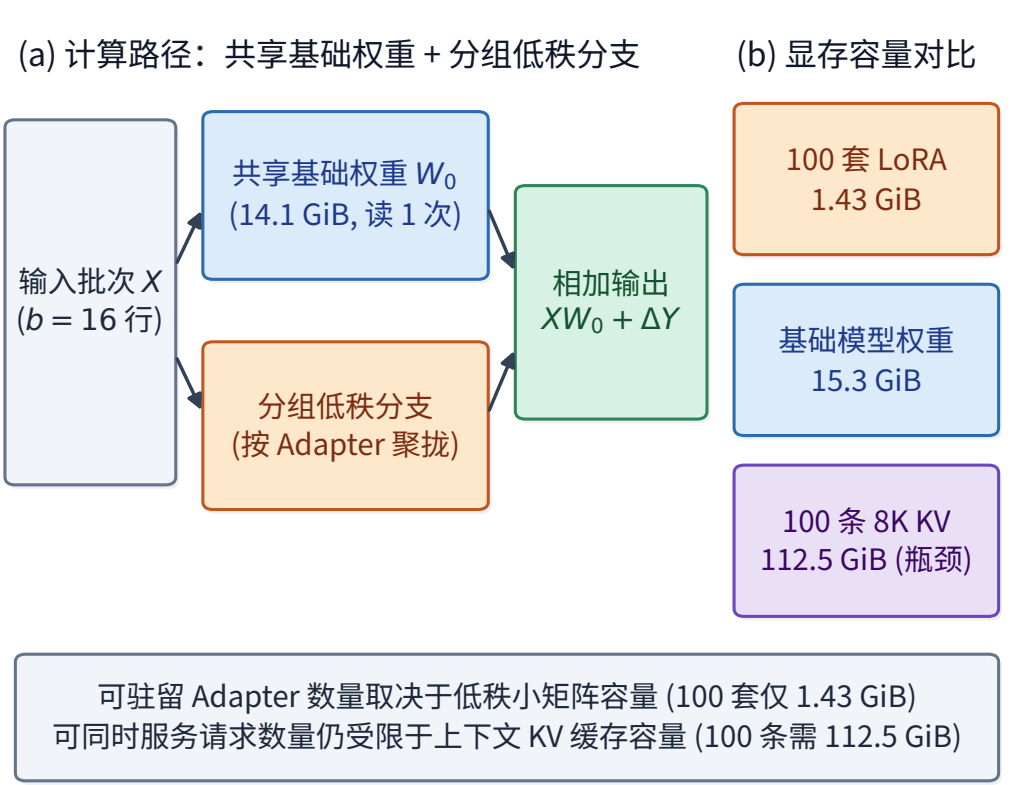
(a) 计算路径：共享基础权重 + 分组低秩分支
(b) 显存容量对比
输入批次 X
(b = 16 行)
共享基础权重 W0
(14.1 GiB, 读 1 次)
分组低秩分支
(按 Adapter 聚拢)
相加输出
XW0 + ΔY
100 套 LoRA
1.43 GiB
基础模型权重
15.3 GiB
100 条 8K KV
112.5 GiB (瓶颈)
可驻留 Adapter 数量取决于低秩小矩阵容量 (100 套仅 1.43 GiB)
可同时服务请求数量仍受限于上下文 KV 缓存容量 (100 条需 112.5 GiB)