多轮对话前缀命中判断与 SWA 局部状态按需恢复路径

路径 A · 热缓存全命中

全局 KV 与编码器 SWA 均在显存

→ **直接送入编码器**

仅处理本轮新增输入 token

路径 B · 仅全局锚点 KV 命中

已淘汰占一半容量的 40 层 SWA

→ **末尾 128-token 局部重放**

重建编码器 SWA 后处理新输入

路径 C · 全局 KV 未命中

前缀超出缓存或首次到达

→ **编码器重算缺失前缀**

补齐全局 KV 与 SWA 后处理新输入

三条路径汇合后统一进入解码器阶段

解码器 20 层末尾窗口重放 → 构建解码器局部 SWA → 自回归生成输出