A. 高吞吐：RDMA->NVLink 转发

源节点 GPU i：跨机专家 Token
先经 RDMA 发往对等 GPU i

目标机 GPU i：经机内 NVLink
二次转发至本机专家 GPU j

跨机 QP 扇出缩减 G=8 倍
消除多卡争抢网卡与队头阻塞

DeepEP V2（SM90/SM100）：
CX7 8×2 达 90/81 GB/s (12 SM)

B. 低延迟：IBGDA 与 0-SM 轮询

GPU 线程直驱网卡门铃 (IBGDA)
绕过 CPU 代理，单跳直达目标卡

接收钩子 (Hook) 后台轮询完成
零 SM 占用，让出算力给 MLA

V2 ElasticBuffer + NCCL Gin：
峰值 1.3×，SM 压降 4× (4-6 SM)

SwiftEP 整形 + cached_handle：
消除微突发排队与解码期同步